

UNIVERSIDAD ANDRÉS BELLO

«Nombre de la carrera»

Sobreduración en la titulación de la educación superior chilena (2020–2025)

Avance del proyecto: Fases 1 y 2 — Implementación inicial del entorno reproducible, exploración y procesamiento de datos

Antecedente	Detalle
Curso	«Nombre del curso» («Código del curso»)
Docente responsable	«Nombre del docente»
Grupo	«N»
Integrantes	«Integrante 1» · «Integrante 2» · «Integrante 3» · «Integrante 4»
Entrega	Primer avance sumativo — Fases 1 y 2
Repositorio GitHub	« https://github.com/usuario/proyecto-titulados »
Fecha de entrega	«dd» de «mes» de 2026
Institución	Universidad Andrés Bello

Documento elaborado por el equipo. Las cifras, tablas y figuras que contiene fueron generadas por los notebooks del repositorio y son reproducibles ejecutando el pipeline documentado en el README.

Índice

Para actualizar el índice en Word: seleccionar la tabla y presionar F9, o hacer clic derecho sobre ella y elegir «Actualizar campos».

II. Introducción y contextualización	5
2.1 Contexto del proyecto	5
2.2 Presentación del problema	5
2.3 Objetivo general del proyecto	5
2.4 Alcance del informe	5
2.5 Justificación técnica	6
2.6 Conexión con las fases F1–F4.....	6
III. Definición de la problemática y objetivos del proyecto	7
3.1 Formulación técnica de la problemática.....	7
3.2 Preguntas centrales del análisis	7
3.3 Objetivo general.....	7
3.4 Objetivos específicos.....	7
3.5 Alcance del proyecto.....	8
3.6 Supuestos relevantes	8
3.7 Articulación del problema con las fases	9
IV. Aplicación de herramientas científicas	10
4.1 Librerías del ecosistema científico de Python.....	10
4.2 Integración de las herramientas en el flujo de trabajo.....	10
4.3 Funciones, módulos y clases que ejecutan el flujo	11
4.4 Reproducibilidad técnica.....	11
4.4.1 Entorno declarado y verificable	11
4.4.2 Registro del entorno dentro de los propios notebooks.....	12
4.4.3 Evidencia de ejecución completa sin errores.....	12
4.5 Control de versiones con Git y GitHub.....	13
4.5.1 Uso de ramas	14
4.5.2 Contribuciones individuales.....	14
4.6 Documentación del proceso y decisiones técnicas.....	14
4.7 Repositorio GitHub	15
V. Diseño de soluciones algorítmicas eficientes	17
5.1 Codificación funcional	17
5.1.1 Fragmento comentado: lectura por bloques	17

5.1.2 Separación de responsabilidades y flujo de datos	17
5.1.3 Programación orientada a objetos	18
5.2 Preprocesamiento y transformación del conjunto de datos	18
5.2.1 Tratamiento de valores faltantes.....	19
5.2.2 Transformación de variables.....	19
5.2.3 Conversión de tipos	20
5.3 Validación técnica y verificación del código	20
5.3.1 Nivel 1: integridad de la carga contra la fuente oficial	20
5.3.2 Nivel 2: reglas de validación sobre el conjunto completo	21
5.3.3 Nivel 3: pruebas automatizadas.....	21
5.3.4 Nivel 4: verificación manual y determinismo	22
VI. Notebook F1_Definición.ipynb	24
VII. Notebooks ejecutables de la Fase 2	25
7.1 Diagnóstico de calidad (F2_1).....	25
7.2 Resultados del análisis exploratorio (F2_3)	25
7.2.1 Magnitud general de la sobreduración.....	26
7.2.2 Evolución anual y efecto de la pandemia	27
7.2.3 Diferencias por área de conocimiento y tipo de institución.....	29
7.2.4 Brecha de género	31
7.2.5 Modalidad de estudio y educación a distancia.....	33
7.2.6 Dimensión territorial.....	34
7.2.7 Carreras con mayor y menor rezago.....	35
VIII. Vinculación del mapa conceptual con el avance del proyecto.....	37
IX. Conclusiones y proyección.....	39
9.1 Sobre el proceso técnico.....	39
9.2 Sobre los hallazgos sustantivos.....	39
9.3 Limitaciones	39
9.4 Proyección a las fases siguientes	39
X. Bibliografía	41
Bibliografía docente.....	41
Documentación técnica oficial.....	41
Fuente de datos	41
Bibliografía complementaria.....	41
XI. Anexos.....	43
Anexo A. Diccionario de variables del conjunto de origen	43

Anexo B. Columnas descartadas y motivo del descarte	44
Anexo C. Salida completa de las pruebas automatizadas.....	44
Anexo D. Contribuciones por integrante	45
Anexo E. Instrucciones de reproducción	45

II. Introducción y contextualización

2.1 Contexto del proyecto

El Servicio de Información de Educación Superior (SIES), dependiente del Ministerio de Educación de Chile, publica anualmente la base de datos de titulados de educación superior por estudiante. Se trata de un registro administrativo censal: contiene una fila por cada título obtenido en el país, con información demográfica, institucional, territorial y curricular. Entre 2020 y 2025 esa base acumula 1.710.167 registros distribuidos en seis archivos anuales que suman aproximadamente 955 MB (SIES, 2026).

Esa escala convierte al conjunto en la fotografía más completa disponible sobre el desenlace de las trayectorias formativas en Chile, pero también lo hace inabordable con herramientas de escritorio: ningún software de planilla de cálculo puede abrir un archivo de 328.998 filas por 40 columnas y, al mismo tiempo, aplicarle transformaciones auditables y reproducibles. El análisis exige programación.

2.2 Presentación del problema

El sistema de educación superior chileno compromete con cada estudiante una duración teórica: el número de semestres que, según el plan de estudios, debería tomar completar la carrera. La base del SIES publica esa duración teórica en tres variables (duración de estudios, duración del proceso de titulación y duración total), pero no publica cuánto tardó efectivamente cada estudiante en titularse.

La diferencia entre ambas magnitudes —lo que este informe denomina **sobreduración**— no es un dato disponible: es una variable que debe construirse. Y sus consecuencias son concretas: cada semestre adicional prolonga el gasto de las familias, extiende el uso de becas y créditos con garantía estatal, retrasa el ingreso al mercado laboral y desajusta la planificación de vacantes de las instituciones.

2.3 Objetivo general del proyecto

Construir, a partir de los registros administrativos de titulados del SIES (2020–2025), un conjunto de datos analítico y reproducible que permita cuantificar y caracterizar la sobreduración de las carreras de pregrado en Chile, identificando las dimensiones institucionales, territoriales, de género y de modalidad asociadas al rezago en la titulación.

2.4 Alcance del informe

Este documento corresponde al primer avance sumativo e integra las Fases 1 y 2 del proyecto transversal. En consecuencia, aborda la definición de la problemática, la configuración del entorno reproducible, la obtención y consolidación de los datos, su exploración, depuración, transformación y validación técnica. Los resultados que se presentan son de carácter exploratorio y descriptivo.

Quedan fuera de este avance la modelación estadística de la sobreduración, prevista para la Fase 3, y la elaboración del reporte analítico final, correspondiente a la Fase 4.

2.5 Justificación técnica

La problemática requiere un enfoque basado en programación por cuatro razones verificables en el propio conjunto de datos:

- **Volumen.** 955 MB distribuidos en seis archivos que deben consolidarse con criterios homogéneos; la lectura ingenua del archivo completo excede la memoria disponible en un equipo estándar y obliga a procesar por bloques.
- **Variable inexistente.** La duración real no está en la fuente: debe derivarse aritméticamente desde el año y semestre de ingreso y la fecha de obtención del título, para 1,25 millones de registros.
- **Calidad heterogénea.** La base codifica la ausencia de información con valores numéricos válidos (9995, 9998, 9999, 19000101). Procesarlos sin tratamiento produce duraciones imposibles: 62.492 registros arrojarían trayectorias de miles de semestres.
- **Trazabilidad.** Un análisis que informa sobre política pública debe permitir que un tercero reproduzca cada cifra. Eso exige control de versiones, entorno declarado y código documentado, no manipulación manual de planillas.

2.6 Conexión con las fases F1–F4

El proyecto se organiza en cuatro fases encadenadas, donde cada una consume el producto de la anterior:

Tabla 1. Articulación de las cuatro fases del proyecto

Fase	Contribución al problema	Producto	Estado
F1	Delimita qué se va a medir y deja operativo un entorno donde el resultado sea reproducible.	Entorno virtual, paquete src/, repositorio Git y notebook de definición	Completada
F2	Construye la variable que no existe en la fuente y garantiza que el conjunto sea confiable.	Conjunto analítico validado y tres notebooks ejecutables	Completada
F3	Aísla el efecto propio de cada factor mediante control multivariado.	Modelo de la sobreduración y evaluación predictiva	Proyectada
F4	Traduce los resultados en evidencia comunicable.	Reporte analítico final con visualizaciones	Proyectada

III. Definición de la problemática y objetivos del proyecto

3.1 Formulación técnica de la problemática

El fenómeno que se busca medir es la brecha entre la duración comprometida y la duración efectiva de las carreras de pregrado en Chile. Formalmente, para cada titulado i se define:

Definición operacional de las variables del proyecto

$duracion_real_i$	$= (anio_titulo_i - anio_ingreso_i) * 2$
	$+ (semestre_titulo_i - semestre_ingreso_i) + 1$
$sobreduracion_i$	$= duracion_real_i - duracion_teorica_i$
$indice_duracion_i$	$= duracion_real_i / duracion_teorica_i$
$titulacion_oportuna$	$= (sobreduracion_i \leq 0)$

La duración se expresa en semestres académicos. El término +1 hace que la métrica cuente semestres cursados y no semestres transcurridos: un estudiante que ingresa y se titula dentro del mismo semestre registra 1 y no 0. La duración teórica corresponde a la variable dur_total_carr publicada por el SIES.

3.2 Preguntas centrales del análisis

1. ¿Cuánto excede la duración real de una carrera de pregrado a su duración teórica, y qué proporción de estudiantes se titula dentro del plazo comprometido?
2. ¿Cómo varía la sobreduración según área de conocimiento, tipo de institución y región de la sede?
3. ¿Existe una brecha de género en los tiempos de titulación, y cómo se relaciona con la composición por sexo de cada área?
4. ¿La expansión de la modalidad no presencial entre 2020 y 2025 se asocia a trayectorias más breves o más largas, y a qué perfil de estudiante corresponde?
5. ¿Qué efecto muestran los datos en 2020, año marcado por la interrupción de la actividad presencial?

3.3 Objetivo general

Construir, a partir de los registros administrativos de titulados de educación superior del SIES (2020–2025), un conjunto de datos analítico y reproducible que permita cuantificar y caracterizar la sobreduración de las carreras de pregrado en Chile, identificando las dimensiones institucionales, territoriales, de género y de modalidad asociadas al rezago en la titulación.

3.4 Objetivos específicos

Tabla 2. Objetivos específicos y su asignación por fase

N.º	Objetivo específico	Fase	Evidencia en esta entrega
OE1	Establecer un entorno de trabajo reproducible: entorno virtual, gestión de dependencias, control de versiones y estructura modular del código.	F1	requirements.txt, src/, repositorio Git
OE2	Consolidar los seis archivos anuales verificando su integridad contra las cifras oficiales del SIES.	F2	src/ingesta.py, notebook F2_1
OE3	Explorar la estructura, distribuciones y problemas de calidad del conjunto consolidado.	F2	Notebook F2_1, sección 7
OE4	Depurar el conjunto documentando cada decisión técnica.	F2	src/limpieza.py, bitácora de limpieza
OE5	Derivar las variables analíticas del proyecto.	F2	src/transformacion.py, notebook F2_2
OE6	Validar técnicamente el conjunto mediante reglas y pruebas automatizadas.	F2	src/validacion.py, tests/, notebook F2_3
OE7	Modelar la sobreduración y evaluar su capacidad predictiva.	F3	Proyectado
OE8	Comunicar los hallazgos en un reporte analítico.	F4	Proyectado

3.5 Alcance del proyecto

Qué se aborda

- Titulados de pregrado entre 2020 y 2025: seis procesos anuales completos.
- Cobertura nacional: 16 regiones, tres tipos de institución y diez áreas de conocimiento.
- Variables demográficas, institucionales, territoriales y curriculares del registro SIES.

Qué queda fuera

- **Posgrado y postítulo** (398.391 registros): sus planes tienen duraciones heterogéneas y no comparables con las de una carrera regular.
- **Deserción y retención**: la base contiene únicamente a quienes se titularon.
- **Series anteriores a 2020**: la ventana se acota a seis años para mantener homogéneo el esquema de variables, dado que la clasificación CINE-F 2013 se incorpora recién en 2021.
- **Inferencia causal**: el diseño es descriptivo y correlacional.

3.6 Supuestos relevantes

Tabla 3. Supuestos metodológicos y sus implicancias

N.º	Supuesto	Implicancia para la interpretación
S1	El año y semestre de ingreso a la carrera de origen representan el inicio real de la trayectoria.	Es la variable que el propio SIES señala como referencia para identificar al estudiante de primer año.

N.º	Supuesto	Implicancia para la interpretación
S2	Un título obtenido hasta julio se imputa al primer semestre; desde agosto, al segundo.	La fuente entrega la fecha exacta pero no el semestre académico; la convención debe declararse explícitamente.
S3	La duración teórica informada corresponde al plan vigente del estudiante.	Los cambios de malla durante la trayectoria no son observables en esta base.
S4	Los registros sin insumos para reconstruir la duración se descartan en lugar de imputarse.	Imputar el año de ingreso equivaldría a inventar la variable que el proyecto mide.
S5	La base cubre la totalidad de los titulados informados por las instituciones.	El SIES documenta solo dos omisiones institucionales, ambas anteriores a 2012.

3.7 Articulación del problema con las fases

El objetivo general se desagrega en las cuatro fases de manera acumulativa. La Fase 1 responde a la pregunta «qué se va a medir y bajo qué condiciones de reproducibilidad»; la Fase 2, a «con qué datos y con qué garantías de calidad»; la Fase 3, a «qué explica las diferencias observadas»; y la Fase 4, a «cómo se comunica la evidencia». Este informe cubre íntegramente las dos primeras.

IV. Aplicación de herramientas científicas

4.1 Librerías del ecosistema científico de Python

El proyecto se apoya en el ecosistema científico estándar de Python. Cada librería cumple un rol delimitado y su versión está fijada en el archivo de dependencias, de modo que el entorno pueda reconstruirse de forma idéntica en cualquier equipo.

Tabla 4. Librerías utilizadas, versión fijada y función en el proyecto

Librería	Versión	Función concreta en este proyecto
pandas	3.0.5	Lectura por bloques de los CSV, tipado, agrupaciones, tablas dinámicas y persistencia en Parquet.
NumPy	2.5.3	Operaciones vectorizadas sobre las variables derivadas y manejo de valores no numéricos (np.nan, np.inf) en los cortes de clasificación.
PyArrow	25.0.1	Motor de escritura y lectura del formato Parquet, que reduce 955 MB de CSV a 37,5 MB conservando los tipos.
Matplotlib	3.11.1	Base de todas las figuras: histogramas, series temporales y barras anotadas.
seaborn	0.13.2	Estilo visual unificado, diagramas de caja y mapas de calor.
JupyterLab	4.6.3	Entorno de los cuatro notebooks que documentan cada fase.
nbconvert	7.17.1	Ejecución no interactiva de los notebooks para verificar que corren de principio a fin sin errores.
pytest	9.1.1	Suite de pruebas automatizadas sobre las funciones del pipeline.

4.2 Integración de las herramientas en el flujo de trabajo

Las herramientas no se usan de manera aislada: se integran en un flujo de cinco etapas donde cada una produce un artefacto que la siguiente consume. Esta separación es la que permite reejecutar una etapa sin repetir las anteriores.

Flujo de datos del proyecto y herramienta responsable de cada etapa

CSV originales del SIES (6 archivos, 955 MB, 1.710.167 filas)		
	src/ingesta.py	pandas.read_csv(chunksize=200.000) + coercion controlada
v		
data/interim/titulados_2020_2025_consolidado.parquet (37,5 MB, 30 columnas)		
	src/limpieza.py	sentinelas -> NA, normalizacion, duplicados, filtros
	src/transformacion.py	duracion real, sobreduracion, edad, categorias
v		
data/processed/titulados_pregrado_analitico.parquet (1.246.760 filas, 47 columnas)		
	src/validacion.py	11 reglas + tests/ (22 pruebas pytest)
v		
reports/figures/*.png y reports/tables/*.csv (17 figuras, 13 tablas)		

La elección de Parquet como formato intermedio es una decisión de eficiencia con efecto medible: la consolidación desde los CSV toma alrededor de 24 segundos, mientras que la lectura del Parquet consolidado toma menos de un segundo. En un proyecto donde la etapa de limpieza se reejecuta muchas veces, esa diferencia determina si el trabajo es viable.

4.3 Funciones, módulos y clases que ejecutan el flujo

El código no reside en los notebooks: vive en el paquete `src/`, y los notebooks lo invocan. Esto evita duplicar lógica entre fases, permite probar cada función de forma aislada y garantiza que el informe y el repositorio describan exactamente el mismo procesamiento.

Tabla 5. Módulos del paquete `src` y su responsabilidad

Módulo	Responsabilidad única	Componentes principales
<code>config.py</code>	Rutas, esquema de datos, constantes de negocio y umbrales.	<code>COLUMNAS_USADAS</code> , <code>FILAS_OFICIALES_SIES</code> , <code>describir_entorno()</code>
<code>ingesta.py</code>	Obtención y consolidación de los archivos anuales.	<code>listar_archivos_raw()</code> , <code>leer_anio()</code> , <code>consolidar()</code>
<code>limpieza.py</code>	Depuración y trazabilidad de las decisiones aplicadas.	<code>marcar_sentinelas()</code> , <code>normalizar_categorias()</code> , clase <code>BitacoraLimpieza</code>
<code>transformacion.py</code>	Derivación de las variables analíticas y agregaciones.	<code>calcular_duracion_real()</code> , <code>calcular_sobreduracion()</code> , <code>tabla_agregada()</code>
<code>validacion.py</code>	Verificación del conjunto mediante reglas declarativas.	clases <code>Regla</code> y <code>ValidadorDataset</code> , <code>validador_estandar()</code>
<code>viz.py</code>	Visualización con estilo unificado y guardado reproducible.	<code>aplicar_estilo()</code> , <code>barras()</code> , <code>histograma()</code> , <code>mapa_calor()</code>
<code>pipeline.py</code>	Orquestación ejecutable de todo el flujo.	<code>ejecutar()</code> , <code>cargar_analitico()</code> , <code>main()</code>

El paquete suma 7 módulos, 30 funciones públicas y 5 clases. Todas las funciones incluyen anotaciones de tipo y `docstring`.

4.4 Reproducibilidad técnica

4.4.1 Entorno declarado y verificable

El proyecto se ejecuta dentro de un entorno virtual aislado, creado con el módulo `venv` de la biblioteca estándar. Ninguna dependencia se instala en el intérprete del sistema, de modo que el entorno de trabajo no depende de lo que cada integrante tenga instalado en su equipo.

Creación del entorno reproducible

<code>python -m venv .venv</code>	
<code>.\.venv\Scripts\Activate.ps1</code>	# Windows PowerShell
<code>source .venv/bin/activate</code>	# Linux / macOS
<code>pip install -r requirements.txt</code>	

Las versiones se fijan con el operador `==` y no con rangos: una actualización silenciosa de pandas podría alterar el comportamiento de una agregación y, con ello, las cifras del informe. El entorno de referencia es Python 3.14.7 sobre Windows 11.

4.4.2 Registro del entorno dentro de los propios notebooks

Cada notebook comienza invocando `config.describir_entorno()`, cuya salida queda guardada en el archivo ejecutado. Así, la versión exacta con la que se produjo cada resultado es parte del documento y no una afirmación externa.

Salida de la celda de arranque, común a los cuatro notebooks

Raíz del proyecto: D:\IA Development\proyecto-titulados	
python	3.14.7
plataforma	Windows-11-10.0.26200-SP0
ejecutable	D:\IA Development\proyecto-titulados\.venv\Scripts\python.exe
numpy	2.5.3
pandas	3.0.5
matplotlib	3.11.1
seaborn	0.13.2
pyarrow	25.0.1

4.4.3 Evidencia de ejecución completa sin errores

El pipeline puede ejecutarse de extremo a extremo con una sola orden. La salida siguiente corresponde a una ejecución real y muestra la bitácora de depuración y el resultado de las once reglas de validación.

Salida de `python -m src.pipeline`

[pipeline] Consolidado cargado: 1,710,167 filas		
paso		
...		
consolidado_inicial		
...		
marcar_sentinelas Codigos SIES y vacios convertidos a NA (anio_ing_carr_ori=62,492, sem_ing_carr_...		
normalizar_categorias		
...		
filtrar_nivel		
...		
eliminar_duplicados		Clave: cat_periodo +
mrun + co...		
descartar_sin_insumos		Filas sin
anio_ing_carr_or...		
construir_dataset_analitico		
D...		
filtrar_atipicos		
...		
regla		estado
...		
dataset_no_vacio	PASA	
1,246,760 filas ...		
columnas_derivadas	PASA	Todas
las variab...		

sin_nulos_criticos Sin nulos e...	PASA	
rango_duracion_real [1, 40] seme...	PASA	Duracion real dentro de
rango_edad dentro de [15...	PASA	Edad de titulacion
dominio_genero Valores observa...	PASA	
coherencia_aritmetica real en 1,246...	PASA	sobreduracion + duracion teorica = duracion
cobertura_anios [2020, 2021,...	PASA	Anios presentes:
titulo_posterior_ingreso titulos con fe...	PASA	0
sin_duplicados cod_carrera +...	PASA	0 duplicados sobre cat_periodo + mrun +
periodo_igual_anio_titulo con el anio...	ADVIERTE 230,563 filas (18.49%) donde el anio del proceso no coincide	
10 reglas aprobadas, 1 advertencias, 0 fallas criticas.		
[pipeline] Dataset analitico: D:\IA Development\proyecto-titulados\data\processed\titulados_pregrado_analit...		

Adicionalmente, los cuatro notebooks se ejecutan de forma no interactiva con nbconvert, lo que verifica que corren completos y en orden dentro del entorno declarado:

```
python -m jupyter nbconvert --to notebook --execute --inplace "F1/F1_Definición.ipynb"
python -m jupyter nbconvert --to notebook --execute --inplace F2/F2_1_Obtencion_Exploracion.ipynb
python -m jupyter nbconvert --to notebook --execute --inplace
F2/F2_2_Limpieza_Transformacion.ipynb
python -m jupyter nbconvert --to notebook --execute --inplace F2/F2_3_Validacion_Analisis.ipynb
```

4.5 Control de versiones con Git y GitHub

El repositorio registra el avance progresivo del proyecto con commits descriptivos que explican qué se hizo y por qué. Se emplea además una rama de trabajo para el desarrollo del pipeline de la Fase 2, integrada a la rama principal mediante una fusión explícita que conserva la historia de la rama.

Tabla 6. Historial de commits del repositorio

Hash	Fecha	Mensaje
4954ad7	2026-09-08	style(viz): rotula las figuras con formato numerico chileno
43035f5	2026-09-08	merge: integra la rama fase-2/pipeline-datos en main
179960e	2026-09-08	docs(f2): ejecuta los notebooks y versiona figuras, tablas y muestra
a95bdd3	2026-09-08	perf(limpieza): normaliza el catalogo de categorias en vez de fila por fila
daf70dd	2026-09-08	fix(viz,transformacion): compatibilidad con los tipos anulables de pandas
1b4b202	2026-09-08	docs(f2): notebooks de obtencion, limpieza, transformacion y validacion
5b3cb36	2026-09-08	docs(f1): notebook de definicion del proyecto y entorno reproducible
cbd0486	2026-09-08	feat(viz,pipeline): estilo unificado de figuras y orquestador ejecutable

Hash	Fecha	Mensaje
34bac9d	2026-09-08	test: cubre casos normales, limite y excepciones del pipeline
36126c1	2026-09-08	feat(validacion): motor de reglas orientado a objetos
ffa9c2e	2026-09-08	feat(transformacion): reconstruye la duracion real y la sobreduracion
61dd691	2026-09-08	feat(limpieza): convierte codigos centinela del SIES en nulos explicitos
f57dfd9	2026-09-08	feat(ingesta): consolida los seis años con lectura por bloques
522dbb3	2026-09-08	feat(config): centraliza rutas, esquema de datos y parametros
579ee29	2026-09-08	chore: inicializa repositorio con entorno reproducible

Los mensajes siguen la convención de commits semánticos (*feat*, *fix*, *docs*, *test*, *perf*, *chore*), que identifica el tipo de cambio y el módulo afectado.

4.5.1 Uso de ramas

Salida de `git log --oneline --graph`

* 43035f5 merge: integra la rama fase-2/pipeline-datos en main
\
* 179960e docs(f2): ejecuta los notebooks y versiona figuras, tablas y muestra
* a95bdd3 perf(limpieza): normaliza el catalogo de categorias en vez de fila por fila
* daf70dd fix(viz,transformacion): compatibilidad con los tipos anulables de pandas
* 1b4b202 docs(f2): notebooks de obtencion, limpieza, transformacion y validacion
/
* 5b3cb36 docs(f1): notebook de definicion del proyecto y entorno reproducible

La rama `fase-2/pipeline-datos` aisló el desarrollo del pipeline de datos mientras la rama principal mantenía un estado estable. La fusión se realizó con la opción `--no-ff`, que preserva el punto de integración en el grafo y permite identificar con precisión qué commits pertenecen a cada fase.

4.5.2 Contribuciones individuales

La evidencia de contribuciones individuales se obtiene con `git shortlog`, que agrupa los commits por autor. Cada integrante debe realizar sus propios commits desde su cuenta, configurando previamente su identidad en el repositorio:

<code>git config user.name "Nombre Apellido"</code>
<code>git config user.email "correo@institucion.cl"</code>
<code>git shortlog -sn --all</code> # contribuciones acumuladas por integrante

4.6 Documentación del proceso y decisiones técnicas

Cada decisión relevante quedó documentada en tres lugares coherentes entre sí: el docstring de la función que la implementa, la celda markdown del notebook que la aplica y este informe. La tabla siguiente resume las decisiones adoptadas junto con la alternativa que se descartó.

Tabla 7. Decisiones técnicas, alternativas descartadas y justificación

Decisión adoptada	Alternativa descartada	Justificación
Lectura por bloques de 200.000 filas	Lectura completa del archivo	La memoria ocupada deja de depender del tamaño del archivo; permite trabajar con 955 MB en equipos estándar.
Lectura como texto y conversión posterior	Tipado directo en read_csv	Un valor no convertible aborta la carga completa; con coerción controlada se registra como incidencia de calidad y el proceso continúa.
Parquet como formato intermedio	CSV intermedio	Conserva los tipos, comprime 25 veces y evita reparsear texto en cada reejecución.
30 de 40 columnas	Conservar todas	CINE-F 1997 es redundante frente a CINE-F 2013; el motivo de cada exclusión está declarado en config.COLUMNAS_DESCARTADAS.
Centinelas convertidos a NA	Filtrar las filas de inmediato	Permite cuantificar cuánta información falta y en qué variables antes de decidir su tratamiento.
Restricción a pregrado	Analizar los tres niveles con control	Los planes de posgrado y postítulo no son comparables en duración; el alcance de la fase exige un conjunto homogéneo.
Descartar registros sin año de ingreso	Imputar con la mediana del programa	Imputar el inicio de la trayectoria equivale a inventar la variable que se pretende medir.
dur_total_carr como duración teórica	Suma de estudio y proceso de titulación	La identidad no se cumple en el 33,5 % de los registros: el proceso ya está contenido en la duración de estudios.
Filas sin mrun fuera del cotejo de duplicados	Deduplicar todas las filas	Pandas considera iguales dos valores nulos; incluirlas colapsaría estudiantes distintos en un solo registro.
Normalizar el catálogo de categorías	Normalizar fila por fila	Reduce el trabajo de 1,7 millones de cadenas por columna a unos pocos miles de valores únicos.

4.7 Repositorio GitHub

El repositorio organiza el trabajo en carpetas por fase (F1 y F2), aísla el código reutilizable en src/, las pruebas en tests/ y las salidas en reports/. El README técnico documenta el propósito del proyecto, su estructura, las dependencias, las instrucciones de ejecución de cada notebook y las decisiones técnicas adoptadas.

Estructura del repositorio

proyecto-titulados/	
-- F1/	
\-- F1_Definición.ipynb	Definición del problema y entorno
-- F2/	
\-- F2_1_Obtencion_Exploracion.ipynb	Consolidación y exploración (EDA)
\-- F2_2_Limpieza_Transformacion.ipynb	Depuración y variables derivadas
\-- F2_3_Validacion_Analisis.ipynb	Validación técnica y resultados
-- src/	Paquete con los 7 módulos del pipeline
-- tests/test_pipeline.py	22 pruebas automatizadas

-- data/		
	-- raw/	CSV originales del SIES (no versionados: 955 MB)
	-- interim/	Consolidado en Parquet (no versionado)
	-- processed/	Conjunto analítico y muestra de 5.000 filas
-- reports/		
	-- figures/	17 figuras generadas por los notebooks
	-- tables/	13 tablas de resultados en CSV
-- docs/		
-- informe/		
Informe técnico de las Fases 1 y 2		
-- requirements.txt		
-- .gitignore		
\-- README.md		

Nota sobre los datos. Los seis CSV originales no se versionan porque cada uno supera el límite de 100 MB por archivo de GitHub. El repositorio incluye el código que los localiza y procesa, la ruta configurable mediante la variable de entorno TITULADOS_RAW_DIR, y una muestra aleatoria reproducible de 5.000 registros del conjunto analítico que permite inspeccionar el resultado sin ejecutar el pipeline completo.

V. Diseño de soluciones algorítmicas eficientes

5.1 Codificación funcional

El código se organiza en funciones de responsabilidad única, con parámetros explícitos y valores de retorno predecibles. Ninguna función modifica su argumento de entrada: todas operan sobre una copia y devuelven un nuevo objeto, de modo que reejecutar una celda de notebook nunca produce un resultado distinto al de la ejecución anterior.

5.1.1 Fragmento comentado: lectura por bloques

La función siguiente resuelve el problema central de la etapa de obtención: leer archivos que no caben cómodamente en memoria sin perder control sobre los tipos de datos.

src/ingesta.py — lectura por bloques con conversión controlada

```
def leer_anio(ruta: Path, chunksize: int = 200_000) -> tuple[pd.DataFrame, dict]:
    """Lee un CSV anual por bloques y devuelve el DataFrame y sus coerciones."""
    bloques: list[pd.DataFrame] = []
    coerciones_totales: dict[str, int] = {}

    lector = pd.read_csv(
        ruta,
        sep=config.SEPARADOR,          # el SIES delimita con punto y coma
        encoding=config.ENCODING,
        usecols=list(config.COLUMNAS_USADAS), # 30 de las 40 columnas
        dtype=str,                      # se lee como texto y se convierte despues
        chunksize=chunksize,            # la memoria no depende del tamaño del archivo
    )
    for bloque in lector:
        bloque, coerciones = _convertir_tipos(bloque)
        for columna, cantidad in coerciones.items():
            coerciones_totales[columna] = coerciones_totales.get(columna, 0) + cantidad
        bloques.append(bloque)

    df = pd.concat(bloques, ignore_index=True)
    return df, coerciones_totales
```

Tres decisiones de diseño están condensadas aquí. Primero, usecols descarta diez columnas en el momento de la lectura y no después, evitando cargarlas en memoria. Segundo, dtype=str desactiva la inferencia automática de tipos, que ante una columna con valores vacíos produciría tipos distintos en cada bloque. Tercero, la función devuelve las coerciones junto con los datos: el llamador recibe no solo el resultado, sino la información sobre su calidad.

5.1.2 Separación de responsabilidades y flujo de datos

El flujo de datos es verificable en cada punto porque cada etapa declara cuántas filas recibió y cuántas entregó. La orquestación completa cabe en una función legible:

src/pipeline.py — encadenamiento de las etapas

```

bitacora = limpieza.BitacoraLimpieza()

df = limpieza.marcar_sentinelas(df, bitacora)      # 1.710.167 -> 1.710.167
df = limpieza.normalizar_categorias(df, bitacora=bitacora)
df = limpieza.filtrar_nivel(df, bitacora=bitacora) # 1.710.167 -> 1.311.776
df = limpieza.eliminar_duplicados(df, bitacora=bitacora)
df = limpieza.descartar_sin_insumos(df, bitacora=bitacora)
df = transformacion.construir_dataset_analitico(df, bitacora)
df = transformacion.filtrar_atipicos(df, bitacora) # -> 1.246.760

```

5.1.3 Programación orientada a objetos

Dos componentes se implementan con clases porque necesitan mantener estado entre llamadas sucesivas, algo que una función pura no puede hacer:

- **BitacoraLimpieza** acumula los pasos aplicados. Cada llamada a registrar() añade un objeto PasoLimpieza con las filas de entrada y salida; el método a_dataframe() convierte el acumulado en la tabla de trazabilidad que se exporta como evidencia.
- **ValidadorDataset** acumula reglas y resultados. Cada Regla es un objeto con nombre, descripción, severidad y función de comprobación; el validador las ejecuta todas, captura las excepciones que cada una pueda lanzar y expone la propiedad aprobado.

src/validacion.py — regla declarativa con manejo de excepciones

```

@dataclass
class Regla:
    nombre: str
    descripcion: str
    funcion: FuncionRegla
    critica: bool = True      # False -> se reporta como advertencia

    def evaluar(self, df: pd.DataFrame) -> dict:
        """Ejecuta la regla capturando cualquier excepcion como incumplimiento."""
        try:
            cumple, detalle = self.funcion(df)
        except Exception as exc:  # la validacion nunca debe abortar el pipeline
            cumple, detalle = False, f"Error al evaluar: {type(exc).__name__}: {exc}"
        return {"regla": self.nombre, "estado": "PASA" if cumple else "FALLA", ...}

```

5.2 Preprocesamiento y transformación del conjunto de datos

El pipeline de preprocesamiento consta de seis pasos aplicados en un orden que no es arbitrario: primero se hace visible lo que falta, luego se homogeneiza, después se acota la población y solo al final se descarta. La bitácora registra el efecto de cada paso sobre el volumen de datos.

Tabla 8. Bitácora de limpieza: efecto de cada paso sobre el volumen de registros

Paso	Filas antes	Filas después	Afectadas	%
consolidado_inicial	1.710.167	1.710.167	0	0.0
marcar_sentinelas	1.710.167	1.710.167	0	0.0
normalizar_categorias	1.710.167	1.710.167	0	0.0
filtrar_nivel	1.710.167	1.311.776	398.391	23.295
eliminar_duplicados	1.311.776	1.311.704	72	0.005
descartar_sin_insumos	1.311.704	1.249.879	61.825	4.713
construir_dataset_analitico	1.249.879	1.249.879	0	0.0
filtrar_atipicos	1.249.879	1.246.760	3.119	0.25

Retención global: 1.246.760 de 1.710.167 registros (72.9 %). La pérdida se concentra en dos decisiones deliberadas: la exclusión de posgrado y postítulo y el descarte de registros sin año de ingreso utilizable.

5.2.1 Tratamiento de valores faltantes

La base del SIES no contiene celdas vacías en la mayoría de sus columnas, lo que podría dar la impresión de un conjunto completo. No lo es: la ausencia de información se codifica con valores numéricos válidos.

Tabla 9. Códigos centinela detectados y tratamiento aplicado

Variable	Código	Significado según el SIES	Registros	Tratamiento
anio_ing_carr_ori	1900/9995/9998/9999	Sin información u origen en otro programa	62.492	A NA y descarte posterior
sem_ing_carr_ori	0	Semestre no informado	62.492	A NA y descarte posterior
fecha_obtencion_titulo	19000101	Fecha por defecto	0	A NA (no se presenta)
fec_nac_alu	190001	Fecha de nacimiento por defecto	38	A NA; se marca como atípico
mrnun	(vacío)	Sin identificador; no documentado	3.534	Se conserva, fuera del cotejo de duplicados
cod_carrera	(vacío)	Sin código de programa; no documentado	31.629	Se conserva: el análisis usa nombre y área

Los dos últimos casos constituyen un hallazgo propio: el esquema oficial del SIES no documenta que estas columnas puedan venir vacías. Se detectaron durante la ingesta gracias a que la conversión de tipos registra las coerciones en lugar de fallar en silencio.

5.2.2 Transformación de variables

Sobre el conjunto depurado se derivan siete variables. La transformación central reconstruye la duración real de la trayectoria, que no existe en la fuente:

```
def calcular_duracion_real(df: pd.DataFrame) -> pd.DataFrame:
    """Calcula la duracion real de la trayectoria, en semestres academicos."""
```

```

anios = df["anio_titulo"].astype("Int32") - df["anio_ing_carr_ori"].astype("Int32")
semestres = df["semestre_titulo"].astype("Int16") - df["sem_ing_carr_ori"].astype("Int16")
df["duracion_real_sem"] = (anios * config.SEMESTRES_POR_ANIO + semestres + 1).astype("Int16")
return df

```

Tabla 10. Variables derivadas, definición y justificación técnica

Variable	Definición	Justificación de la transformación
duracion_real_sem	(año título – año ingreso) × 2 + (semestre título – semestre ingreso) + 1	Reconstruye el dato ausente en la fuente. El +1 mide semestres cursados y no transcurridos, evitando que una trayectoria válida registre cero.
sobreduracion_sem	duración real – duración teórica	Variable objetivo del proyecto; expresa el rezago en la unidad natural del sistema (semestres).
indice_duracion	duración real ÷ duración teórica	Permite comparar planes de distinta extensión: dos semestres de rezago no significan lo mismo en una carrera de 4 que en una de 12.
titulacion_oportuna	sobreduración ≤ 0	Indicador binario, directamente utilizable como variable dependiente en la clasificación prevista para la Fase 3.
categoria_rezago	Oportuna / leve (≤2) / moderado (≤4) / severo (>4)	Segmenta la distribución en grupos interpretables para la comunicación de resultados.
edad_titulacion	año título – año nacimiento, ajustado por mes	Caracteriza el perfil etario; el ajuste por mes evita sobreestimar la edad en promedio medio año.
genero	Etiqueta legible de gen_alu	Sustituye los códigos 1 y 2 por Hombre y Mujer según el esquema oficial, eliminando ambigüedad en las tablas.

5.2.3 Conversión de tipos

Las variables enteras que admiten ausencia de dato se convierten a los tipos anulables de pandas (Int8, Int16, Int32, Int64) y no a float. La diferencia no es cosmética: en punto flotante, un año de ingreso se representaría como 2018.0 y cualquier comparación exacta podría fallar por error de redondeo. Las variables categóricas se convierten al tipo category, lo que reduce la memoria del conjunto consolidado de aproximadamente 1,2 GB a 100 MB.

5.3 Validación técnica y verificación del código

La verificación se realiza en cuatro niveles complementarios, cada uno con evidencia registrada en el repositorio.

5.3.1 Nivel 1: integridad de la carga contra la fuente oficial

El esquema de registro del SIES publica el número exacto de observaciones por año. La ingesta compara ambos conteos; una diferencia distinta de cero detendría el proceso.

Tabla 11. Verificación de integridad de la carga por año

Año	Filas cargadas	Filas oficiales SIES	Diferencia	Estado
2020	203.598	203.598	0	OK
2021	281.491	281.491	0	OK
2022	291.460	291.460	0	OK
2023	299.893	299.893	0	OK
2024	304.727	304.727	0	OK
2025	328.998	328.998	0	OK
Total	1.710.167	1.710.167	0	OK

5.3.2 Nivel 2: reglas de validación sobre el conjunto completo

Once reglas verifican el conjunto analítico resultante. Las críticas invalidan el conjunto si fallan; las advertencias señalan comportamientos que deben documentarse.

Tabla 12. Resultado de las reglas de validación aplicadas al conjunto analítico

Regla	Severidad	Estado	Detalle
dataset_no_vacio	critica	PASA	1,246,760 filas en el dataset analítico.
columnas_derivadas	critica	PASA	Todas las variables derivadas presentes.
sin_nulos_criticos	critica	PASA	Sin nulos en las columnas críticas.
rango_duracion_real	critica	PASA	Duración real dentro de [1, 40] semestres; 0 fuera de rango.
rango_edad	critica	PASA	Edad de titulación dentro de [15, 90]; 0 fuera de rango.
dominio_genero	critica	PASA	Valores observados: ['Hombre', 'Mujer']
coherencia_aritmetica	critica	PASA	sobreduración + duración teórica = duración real en 1,246,760 de 1,246,760 filas.
cobertura_anios	critica	PASA	Años presentes: [2020, 2021, 2022, 2023, 2024, 2025]
titulo_posterior_ingreso	critica	PASA	0 títulos con fecha anterior al ingreso.
sin_duplicados	critica	PASA	0 duplicados sobre cat_período + mrun + cod_carrera + fecha_obtencion_titulo.
periodo_igual_anio_titulo	advertencia	ADVIERTE	230,563 filas (18.49%) donde el año del proceso no coincide con el año de la fecha del título.

Resultado: 10 reglas aprobadas, 1 advertencia, 0 fallas críticas.

La única regla no aprobada es una advertencia: en un 18,5 % de los registros el año del proceso no coincide con el año de la fecha del título. El análisis del desfase muestra que se concentra en los meses extremos del año, lo que confirma que corresponde al calendario administrativo del SIES —títulos de fin de año informados en el proceso siguiente— y no a un error de procesamiento.

5.3.3 Nivel 3: pruebas automatizadas

La suite de pytest cubre los tres escenarios exigidos: casos normales, casos límite y excepciones. No depende de los CSV originales, pues construye los DataFrame de prueba en memoria, y se ejecuta en menos de dos segundos.

Tabla 13. Cobertura de la suite de pruebas automatizadas

Escenario	Qué verifica	Pruebas
Casos normales	Duración real, sobreduración, índice, categoría de rezago, edad ajustada por mes e imputación del semestre de titulación.	5
Casos límite	Duración mínima de un semestre, bordes exactos de la clasificación (0, 2 y 4), duración teórica cero sin división por cero, centinelas convertidos a NA, duplicados sin identificador y normalización de nombres propios.	7
Excepciones	Archivos de origen faltantes, Parquet inexistente, conjunto corrupto, validador consultado antes de ejecutarse y regla que lanza una excepción.	6
Agregaciones y entorno	Umbral mínimo de casos en las tablas agregadas, formato numérico de los rótulos y disponibilidad de las librerías declaradas.	4

Salida de `pytest tests/ -v`

===== test session starts =====
tests/test_pipeline.py::test_duracion_real_caso_normal PASSED [4%]
tests/test_pipeline.py::test_sobreduracion_y_categoria PASSED [9%]
tests/test_pipeline.py::test_edad_descuenta_mes_no_cumplido PASSED [13%]
tests/test_pipeline.py::test_edad_cuando_aun_no_cumple_anios PASSED [18%]
tests/test_pipeline.py::test_semestre_de_titulacion_segun_mes PASSED [22%]
tests/test_pipeline.py::test_duracion_minima_es_uno PASSED [27%]
tests/test_pipeline.py::test_clasificacion_en_los_bordes PASSED [31%]
tests/test_pipeline.py::test_sentinelas_se_convierten_en_na PASSED [36%]
tests/test_pipeline.py::test_normalizacion_de_texto_respeto_nombres_propios PASSED [40%]
tests/test_pipeline.py::test_duplicados_sin_mrun_no_se_colapsan PASSED [45%]
tests/test_pipeline.py::test_duplicado_exacto_se_elimina PASSED [50%]
tests/test_pipeline.py::test_duracion_teorica_cero_no_divide_por_cero PASSED [54%]
tests/test_pipeline.py::test_registro_sin_fecha_nacimiento_se_marca_atipico PASSED [59%]
tests/test_pipeline.py::test_archivos_faltantes_lanza_excepcion PASSED [63%]
tests/test_pipeline.py::test_cargar_consolidado_inexistente PASSED [68%]
tests/test_pipeline.py::test_validador_detecta_dataset_corrupto PASSED [72%]
tests/test_pipeline.py::test_validador_aprueba_dataset_correcto PASSED [77%]
tests/test_pipeline.py::test_estado_antes_de_ejecutar_lanza_error PASSED [81%]
tests/test_pipeline.py::test_regla_con_excepcion_se_reporta_como_falla PASSED [86%]
tests/test_pipeline.py::test_tabla_agregada_respeto_minimo_de_casos PASSED [90%]
tests/test_pipeline.py::test_formato_numerico_chileno PASSED [95%]
tests/test_pipeline.py::test_configuracion_expone_versiones PASSED [100%]
===== 22 passed in 1.68s =====

5.3.4 Nivel 4: verificación manual y determinismo

Antes de aplicar la fórmula a 1,25 millones de registros se comprobó sobre casos contruidos a mano, incluido el caso límite de ingreso y titulación en el mismo semestre. El notebook F2_2 documenta la

comparación entre el cálculo manual y el resultado del código, con una aserción que detendría la ejecución ante cualquier discrepancia.

Por último, el notebook F2_3 reejecuta el pipeline completo desde el consolidado y compara el resultado con el conjunto guardado: número de registros, número de columnas, suma de la sobreduración y recuento de titulaciones oportunas. La coincidencia exacta de los cuatro indicadores acredita que el flujo es determinista.

VI. Notebook F1_Definición.ipynb

El notebook de la Fase 1 contiene 31 celdas —16 de documentación en markdown y 15 de código— y se ejecuta completo sin errores dentro del entorno configurado. Su alcance se restringe deliberadamente a lo propio de la Fase 1: no consolida ni transforma el conjunto de datos, tarea que corresponde a la Fase 2.

Tabla 14. Estructura del notebook F1_Definición.ipynb

Sección	Contenido	Evidencia que produce
1–4. Definición	Contexto, problemática, preguntas, objetivos, alcance y supuestos.	Celdas markdown con tablas
5. Mapa conceptual	Correspondencia entre cada componente del mapa y su implementación.	Tabla de trazabilidad
6. Entorno	Versiones de Python y librerías; correspondencia con requirements.txt.	Salida con versiones; aserción de dependencias
7. Estructura	Árbol de carpetas del repositorio generado por código.	Árbol impreso con tamaños
8. Datos de origen	Inventario de los seis archivos y sus cifras oficiales.	Tabla de inventario
9. Primera lectura	Muestra de 1.000 filas y verificación del esquema de columnas.	Aserción de esquema; vista previa
10. Código base	Demostración de la modularidad, las clases con estado y el cálculo central.	Bitácora y validador de ejemplo; verificación manual
11. Pruebas	Ejecución de la suite de pytest desde el propio notebook.	Salida de las 22 pruebas
12. Trazabilidad Git	Rama, commit actual, historial y contribuciones.	Salida de git log y git shortlog
13. Cierre	Estado alcanzado y proyección a las fases siguientes.	Tabla de estado por fase

La sección 10 cumple el requisito de evidenciar modularidad y programación orientada a objetos en esta etapa: instancia la clase BitacoraLimpieza, registra tres pasos ficticios y muestra la tabla resultante; luego construye un conjunto de seis registros de ejemplo, le aplica las transformaciones y ejecuta sobre él las once reglas de validación.

VII. Notebooks ejecutables de la Fase 2

La Fase 2 se documenta en tres notebooks encadenados, cada uno con un alcance delimitado. La separación responde a un criterio técnico: el diagnóstico de calidad debe quedar registrado antes de aplicar cualquier corrección, para que las decisiones de limpieza puedan justificarse con evidencia y no con impresiones.

Tabla 15. Notebooks de la Fase 2, su alcance y sus artefactos

Notebook	Alcance	Consume	Produce
F2_1_Obtencion_Exploracion	Consolidación verificada, descripción del esquema, diagnóstico de calidad y exploración visual.	6 CSV del SIES	Parquet consolidado; tabla de hallazgos
F2_2_Limpieza_Transformacion	Seis pasos de depuración documentados y derivación de las siete variables analíticas.	Parquet consolidado	Conjunto analítico; bitácora
F2_3_Validacion_Analisis	Validación por reglas, pruebas, comprobación de determinismo y resultados.	Conjunto analítico	17 figuras; 13 tablas

7.1 Diagnóstico de calidad (F2_1)

Tabla 16. Inventario de problemas de calidad detectados en la exploración

ID	Hallazgo	Magnitud	Tratamiento aplicado
H1	Códigos centinela en año y semestre de ingreso	62,492 registros	Convertir a NA y descartar: sin fecha de inicio no hay duración que medir
H2	Identificador de estudiante vacío	3,534 registros	Conservar, pero excluir del cotejo de duplicados
H3	Código de carrera vacío	31,629 registros	Conservar: el análisis usa el nombre y el área, no el código
H4	Duraciones teóricas internamente incoherentes	572,146 registros	Usar dur_total_carr como única referencia teórica
H5	Posgrado y postítulo mezclados con pregrado	398,391 registros	Filtrar: planes no comparables en duración
H6	Categorías de texto con formato heterogéneo	18 columnas categóricas	Normalizar espacios y capitalización antes de agrupar
H7	Ausencia de la variable de duración real	no existe en la fuente	Derivarla desde ingreso y fecha de titulación

7.2 Resultados del análisis exploratorio (F2_3)

Las secciones siguientes responden las preguntas planteadas en la Fase 1. Todas las cifras provienen de las tablas exportadas en reports/tables y son reproducibles reejecutando los notebooks.

7.2.1 Magnitud general de la sobreduración

Tabla 17. Indicadores generales del conjunto analítico

Indicador	Valor
Titulados de pregrado analizados (2020–2025)	1.246.760
Duración teórica media del plan (semestres)	7,39
Duración real media (semestres)	10,15
Sobreduración media (semestres)	2,76
Sobreduración mediana (semestres)	1
Índice de duración medio (real ÷ teórica)	1,43
Titulación dentro del plazo teórico	19,0 %
Edad media al titularse (años)	27,9

Hallazgo 1. Solo el 19,0 % de los titulados de pregrado egresa dentro del plazo comprometido por su plan de estudios. La sobreduración media es de 2,76 semestres —cerca de un año y medio adicional— y el índice de duración medio de 1,43 indica que una carrera toma en promedio un 43 % más de tiempo del planificado. Uno de cada cinco titulados (20,4 %) acumula un rezago severo, superior a dos años.




Figura 1. Distribución de la sobreduración en pregrado (2020–2025). La línea vertical marca la titulación dentro del plazo teórico.




Figura 2. Duración teórica de los planes frente a la duración real observada. La distribución completa se desplaza hacia la derecha.




Figura 3. Distribución de los titulados según categoría de rezago.

7.2.2 Evolución anual y efecto de la pandemia

Tabla 18. Sobreduración y titulación oportuna por año del proceso

Año	Titulados	Sobreduración media	Titulación oportuna
2020	159.491	2,50 sem.	17,9 %

Año	Titulados	Sobreduración media	Titulación oportuna
2021	219.642	2,96 sem.	15,2 %
2022	217.356	2,89 sem.	18,4 %
2023	217.784	2,96 sem.	18,7 %
2024	212.103	2,68 sem.	21,1 %
2025	220.384	2,50 sem.	22,3 %

Hallazgo 2. El año 2020 registra 159.491 titulados de pregrado, un 27,4 % menos que 2021: la suspensión de la actividad presencial desplazó exámenes de grado y ceremonias de titulación hacia el año siguiente. Superado ese ajuste, la titulación oportuna mejora de forma sostenida, desde 15,2 % en 2021 hasta 22,3 % en 2025: 7,1 puntos porcentuales de recuperación.




Figura 4. Titulados de educación superior por año del proceso, todos los niveles.




Figura 5. Evolución del porcentaje de titulación oportuna en pregrado.

7.2.3 Diferencias por área de conocimiento y tipo de institución

Tabla 19. Sobreduración por área de conocimiento

Área de conocimiento	Titulados	Sobreduración media	Titulación oportuna
Derecho	28.748	5,77 sem.	8,7 %
Ciencias Básicas	13.505	4,50 sem.	6,3 %
Tecnología	317.385	3,63 sem.	14,1 %
Agropecuaria	30.915	3,57 sem.	10,7 %
Humanidades	7.813	2,72 sem.	15,9 %
Arte y Arquitectura	54.065	2,65 sem.	19,0 %
Administración y Comercio	285.186	2,42 sem.	21,7 %
Salud	232.468	2,37 sem.	21,9 %
Ciencias Sociales	129.637	2,01 sem.	21,8 %
Educación	147.038	1,93 sem.	22,4 %




Figura 6. Sobreduración media por área de conocimiento.

Tabla 20. Sobreduración por tipo de institución

Tipo de institución	Titulados	Sobreduración media	Titulación oportuna
Universidades	569.497	3,32 sem.	12,8 %
Centros de Formación Técnica	214.592	2,83 sem.	13,9 %
Institutos Profesionales	462.671	2,05 sem.	28,9 %




Figura 7. Porcentaje de titulación oportuna según tipo de institución.




Figura 8. Sobreduración media por área de conocimiento y tipo de institución.

Hallazgo 3. La sobreduración es marcadamente heterogénea entre áreas: Derecho (5,77 semestres) y Ciencias Básicas (4,50) casi triplican a Educación (1,93). En Derecho solo el 8,7 % se titula a tiempo, frente al 22,4 % en Educación.

Hallazgo 4. Por tipo de institución, las universidades promedian 3,32 semestres de sobreduración y apenas un 12,8 % de titulación oportuna, mientras que los institutos profesionales promedian 2,05 y alcanzan un 28,9 %. La brecha se explica en parte por la extensión de los planes universitarios y por sus procesos de titulación —tesis, exámenes de grado, prácticas prolongadas—, que en los institutos profesionales suelen estar incorporados al plan regular.

7.2.4 Brecha de género

Tabla 21. Sobreduración según sexo del estudiante

Sexo	Titulados	Sobreduración media	Titulación oportuna
Hombre	542.694	3,29 sem.	16,0 %
Mujer	704.066	2,35 sem.	21,3 %

Tabla 22. Participación femenina y brecha de sobreduración por área

Área de conocimiento	Mujeres (%)	Brecha mujeres – hombres (semestres)
Educación	80,1	-0,88
Salud	79,0	-0,44
Ciencias Sociales	72,4	-0,55
Humanidades	64,6	-0,30
Arte y Arquitectura	63,5	-0,97
Administración y Comercio	59,4	-0,42
Derecho	57,0	-0,66
Agropecuaria	56,6	-0,52
Ciencias Básicas	43,2	-0,14
Tecnología	19,0	-0,18

Una brecha negativa indica que las mujeres se titulan antes que los hombres en esa área.




Figura 9. Composición por sexo de los titulados según área de conocimiento.




Figura 10. Sobreduración media por área de conocimiento y sexo.

Hallazgo 5. Las mujeres se titulan sistemáticamente antes: 2,35 semestres de sobreduración frente a 3,29 de los hombres —una brecha de 0,94 semestres— y 21,3 % frente a 16,0 % de titulación oportuna. La ventaja se observa en las diez áreas de conocimiento, sin excepción. La composición por sexo, en cambio, está fuertemente segregada: las mujeres son el 80,1 % de los titulados en Educación y el 79,0 % en Salud, pero solo el 19,0 % en Tecnología, el área de mayor volumen del sistema.

7.2.5 Modalidad de estudio y educación a distancia

Tabla 23. Sobreduración y perfil etario según modalidad

Modalidad	Titulados	Sobreduración media	Titulación oportuna	Edad media
Presencial	1.126.649	2,86 sem.	17,2 %	27,0 años
No Presencial	97.184	1,84 sem.	34,6 %	37,4 años
Semipresencial	22.927	1,74 sem.	39,7 %	35,0 años




Figura 11. Participación de la modalidad no presencial en la titulación de pregrado.

Hallazgo 6. La modalidad no presencial pasó de 4,7 % de los titulados de pregrado en 2020 a 11,2 % en 2025, con un crecimiento del 230 % en volumen (de 7.492 a 24.697 titulados). Quienes egresan por esta vía muestran menos sobreduración (1,84 frente a 2,86 semestres) y casi el doble de titulación oportuna.

Advertencia interpretativa. La comparación no debe leerse como un efecto de la modalidad: el perfil de quienes la cursan es distinto. La edad media de titulación en modalidad no presencial es de 37,4 años frente a 27,0 en la presencial, y sus planes son más cortos. Se trata mayoritariamente de personas adultas que cursan programas de continuidad de estudios. Aislar el efecto propio de la modalidad exige el control multivariado previsto para la Fase 3.

7.2.6 Dimensión territorial

Tabla 24. Regiones con mayor y menor sobreduración media

Región de la sede	Titulados	Sobreduración media
Atacama	14.809	3,69 sem.
Antofagasta	41.221	3,64 sem.
Arica y Parinacota	15.943	3,63 sem.
Tarapacá	19.979	3,53 sem.
Los Ríos	24.290	3,44 sem.
...	...	...
Ñuble	27.264	2,70 sem.
La Araucanía	54.825	2,59 sem.

Región de la sede	Titulados	Sobreduración media
Metropolitana	592.405	2,58 sem.
Lib. Gral. B. O'Higgins	32.583	2,54 sem.
Maule	62.321	2,43 sem.




Figura 12. Sobreduración media por región de la sede.

Hallazgo 7. La sobreduración es mayor en las regiones extremas del norte —Atacama (3,69), Antofagasta (3,64) y Arica y Parinacota (3,63)— y menor en Maule (2,43), O'Higgins (2,54) y la Región Metropolitana (2,58). La diferencia entre los extremos supera un semestre completo. La composición de la oferta explica parte del patrón: las regiones mineras concentran carreras técnicas y de ingeniería, que son precisamente las de mayor rezago.

7.2.7 Carreras con mayor y menor rezago

Tabla 25. Carreras con mayor y menor sobreduración (mínimo 3.000 titulados)

Carrera	Titulados	Sobreduración media	Oportuna
Prevencion de Riesgos	3.480	7,57 sem.	19,3 %
Mecanica Automotriz en Sistemas Electronicos	5.813	6,57 sem.	0,2 %
Derecho	23.808	6,40 sem.	4,2 %
Medicina Veterinaria	7.458	5,02 sem.	7,7 %
Ingenieria Civil	3.996	4,71 sem.	6,0 %
Tecnico en Mantenimiento Industrial	5.748	4,71 sem.	3,0 %

Carrera	Titulados	Sobreduración media	Oportuna
Electricidad Industrial Mención Instalaciones Eléctricas	3.185	4,47 sem.	1,3 %
Ingeniería en Maquinaria, Vehículos Automotrices y Sistemas Electrónicos	5.700	4,37 sem.	0,4 %
...	...	...	...
Técnico en Odontología	8.097	1,23 sem.	44,9 %
Técnico de Nivel Superior en Trabajo Social	3.892	1,13 sem.	31,8 %
Técnico en Administración	6.575	1,10 sem.	51,9 %
Pedagogía en Educación Parvularia	3.304	1,06 sem.	27,2 %
Técnico en Cosmetología	3.521	0,90 sem.	67,0 %
Técnico de Nivel Superior en Educación Parvularia	6.623	0,89 sem.	39,5 %
Asistente de Parvulos	8.577	0,87 sem.	63,6 %
Técnico de Nivel Superior en Enfermería	6.229	0,80 sem.	40,4 %




Figura 13. Carreras con mayor y menor sobreduración media.

VIII. Vinculación del mapa conceptual con el avance del proyecto

El mapa conceptual técnico elaborado en la actividad formativa organizó el proyecto en componentes encadenados. La tabla siguiente establece la correspondencia explícita entre cada componente planificado y su materialización efectiva en esta entrega, indicando el archivo del repositorio donde puede verificarse.

Tabla 26. Correspondencia entre el mapa conceptual y la implementación realizada

Componente del mapa	Materialización concreta	Evidencia verificable	Estado
Entorno reproducible	Entorno virtual con dependencias fijadas y verificación automática.	requirements.txt; F1 §6	Materializado
Control de versiones	Repositorio Git con 15 commits descriptivos, una rama de trabajo y una fusión explícita.	git log; F1 §12	Materializado
Estructura modular	Paquete src/ con 7 módulos, 30 funciones y 5 clases.	src/; F1 §10	Materializado
Obtención de datos	Lectura por bloques y consolidación verificada contra el SIES.	src/ingesta.py; F2_1 §2	Materializado
Exploración (EDA)	Descripción del esquema, distribuciones y diagnóstico de siete problemas de calidad.	F2_1 §3–§7	Materializado
Limpieza y depuración	Seis pasos con bitácora de trazabilidad y justificación por paso.	src/limpieza.py; F2_2 §2–§6	Materializado
Transformación	Siete variables derivadas, entre ellas la variable objetivo del proyecto.	src/transformacion.py; F2_2 §7	Materializado
Validación técnica	Motor de 11 reglas más 22 pruebas automatizadas y comprobación de determinismo.	src/validacion.py; tests/; F2_3 §2–§4	Materializado
Visualización	17 figuras con estilo unificado, guardadas de forma reproducible.	src/viz.py; reports/figures/	Materializado
Documentación técnica	README técnico, docstrings, celdas markdown e informe coherentes entre sí.	README.md; notebooks	Materializado
Modelación	Predicción de la sobreduración y clasificación de la titulación oportuna.	Insumo disponible: conjunto analítico validado	Proyectado F3
Comunicación de hallazgos	Reporte analítico final destinado a un público no técnico.	Insumo disponible: catálogo de figuras y tablas	Proyectado F4

De los doce componentes planificados, diez están materializados en esta entrega y dos quedan proyectados para las fases siguientes, con sus insumos ya disponibles. La coherencia entre planificación y desarrollo puede verificarse de manera directa: cada afirmación de este informe remite a un archivo del repositorio y a una celda ejecutada de un notebook.

IX. Conclusiones y proyección

9.1 Sobre el proceso técnico

El avance cumple los seis objetivos específicos comprometidos para las Fases 1 y 2. Se construyó un entorno reproducible con dependencias fijadas, se consolidaron 1.710.167 registros con coincidencia exacta contra las cifras oficiales del SIES, y se produjo un conjunto analítico de 1.246.760 titulados de pregrado con siete variables derivadas, validado por once reglas y respaldado por veintiuna pruebas automatizadas.

El aporte técnico central no fue el procesamiento en sí, sino la constatación de que la variable de interés no existía en la fuente. La base publica la duración teórica de los planes, no el tiempo efectivo de las trayectorias; reconstruirlo exigió definir una convención explícita para el semestre de titulación, tratar seis tipos de codificación centinela y descartar de manera justificada los registros irre recuperables.

9.2 Sobre los hallazgos sustantivos

Los resultados exploratorios muestran que la titulación dentro del plazo comprometido es la excepción y no la regla: solo el 19,0 % de los titulados de pregrado egresa a tiempo, con una sobreduración media de 2,76 semestres. El rezago no se distribuye de manera uniforme: se concentra en las carreras universitarias largas, en las áreas de Derecho y Ciencias Básicas, en los hombres y en las regiones extremas del norte.

Dos tendencias temporales resultan relevantes para la política pública. La primera es la recuperación sostenida de la titulación oportuna tras el impacto de 2020. La segunda es la expansión acelerada de la modalidad no presencial, que en seis años triplicó su volumen y que atiende a una población diez años mayor que la presencial.

9.3 Limitaciones

6. Sesgo de selección: la base contiene únicamente a quienes se titularon, de modo que las carreras con mayor deserción podrían mostrar una sobreduración artificialmente baja.
7. Cambios de plan no observables: si un estudiante cambia de malla, la duración teórica registrada puede no corresponder a la que efectivamente cursó.
8. Registros descartados: se excluyó un 4,7 % de los registros de pregrado por carecer de año de ingreso utilizable, en su mayoría estudiantes provenientes de otro programa o institución.
9. Carácter descriptivo: las diferencias entre grupos son asociaciones y no efectos causales, pues no se controla por variables simultáneas.

9.4 Proyección a las fases siguientes

Tabla 27. Trabajo previsto e insumos disponibles para F3 y F4

Fase	Trabajo previsto	Insumo que aporta esta entrega
F3	Modelar la sobreduración mediante regresión y la titulación oportuna mediante clasificación, con control multivariado de área, institución, modalidad, sexo y territorio.	Conjunto analítico con la variable objetivo construida, validada y documentada.
F4	Elaborar el reporte analítico final y comunicar los hallazgos a un público no especializado.	Catálogo de 17 figuras y 13 tablas reproducibles, con estilo unificado.

X. Bibliografía

Referencias en formato APA 7.ª edición. Las fuentes marcadas con «» deben completarse con los datos exactos del material del curso.

Bibliografía docente

«Apellido, N.» (2026). «Título del recurso de la semana 1: herramientas de software científico y entornos reproducibles» [Material del curso «Nombre del curso»]. Universidad Andrés Bello.

«Apellido, N.» (2026). «Título del recurso de la semana 1: exploración y preprocesamiento de datos con el ecosistema científico de Python» [Material del curso «Nombre del curso»]. Universidad Andrés Bello.

Documentación técnica oficial

Matplotlib Development Team. (2025). Matplotlib documentation (versión 3.11). <https://matplotlib.org/stable/index.html>

NumPy Developers. (2025). NumPy documentation (versión 2.5). <https://numpy.org/doc/stable/>

pandas Development Team. (2025). pandas documentation (versión 3.0). <https://pandas.pydata.org/docs/>

Project Jupyter. (2025). JupyterLab documentation. <https://jupyterlab.readthedocs.io/en/stable/>

Fuente de datos

Servicio de Información de Educación Superior. (2026). Titulados de educación superior 2007–2025: bases de datos por estudiante [Conjunto de datos]. Ministerio de Educación de Chile. <https://datosabiertos.mineduc.cl/>

Servicio de Información de Educación Superior. (2026). Esquema de registro: titulados de educación superior 2007–2025 por estudiante. Ministerio de Educación de Chile.

Bibliografía complementaria

Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., Wieser, E., Taylor, J., Berg, S., Smith, N. J., Kern, R., Picus, M., Hoyer, S., van Kerkwijk, M. H., Brett, M., Haldane, A., del Río, J. F., Wiebe, M., Peterson, P., ... Oliphant, T. E. (2020). Array programming with NumPy. *Nature*, 585(7825), 357–362. <https://doi.org/10.1038/s41586-020-2649-2>

McKinney, W. (2022). Python for data analysis: Data wrangling with pandas, NumPy, and Jupyter (3.ª ed.). O'Reilly Media.

Rule, A., Birmingham, A., Zuniga, C., Altintas, I., Huang, S.-C., Knight, R., Moshiri, N., Nguyen, M. H., Rosenthal, S. B., Pérez, F., & Rose, P. W. (2019). Ten simple rules for writing and sharing computational

analyses in Jupyter Notebooks. PLOS Computational Biology, 15(7), e1007007.
<https://doi.org/10.1371/journal.pcbi.1007007>

XI. Anexos

Anexo A. Diccionario de variables del conjunto de origen

Definiciones tomadas del esquema de registro oficial del SIES (secciones 1.2 y Anexo I). Se listan las variables utilizadas en el proyecto.

Variable	Descripción	Valores y códigos especiales
cat_periodo	Año académico del proceso de titulación	2020 a 2025
mrnun	Identificador anonimizado del estudiante	Entero; puede venir vacío
gen_alu	Sexo del estudiante	1: Hombre; 2: Mujer
fec_nac_alu	Fecha de nacimiento (AAAA-MM)	190001: sin información
rango_edad	Rango etario del estudiante	Siete categorías
anio_ing_carr_ori	Año de ingreso a la carrera de origen	9995: sin información; 9998: otro programa en la misma institución; 9999/1900: otra institución
sem_ing_carr_ori	Semestre de ingreso a la carrera de origen	1 o 2; 0: no informado
fecha_obtencion_titulo	Fecha de obtención del título (AAAA-MM-DD)	19000101: sin información
tipo_inst_1 / tipo_inst_2	Clasificación institucional	Universidad / IP / CFT; CRUCH y privadas
cod_inst / nomb_inst	Código y nombre de la institución	Texto y entero
cod_carrera / nomb_carrera	Código y nombre del programa	El código puede venir vacío
nivel_global	Nivel del programa	Pregrado / Postgrado / Postítulo
nivel_carrera_1 / nivel_carrera_2	Nivel formativo detallado	Diez categorías (Anexo I del SIES)
dur_estudio_carr	Duración teórica de estudios (semestres)	Entero
dur_proceso_tit	Duración teórica del proceso de titulación	Entero
dur_total_carr	Duración teórica total del plan	Entero; referencia usada en el proyecto
region_sede / provincia_sede / comuna_sede	Localización de la sede	16 regiones
jornada	Jornada del programa	Diurna, vespertina, a distancia, semipresencial, otra
modalidad	Modalidad de impartición	Presencial, semipresencial, no presencial
tipo_plan_carr	Tipo de plan	Regular, especial, regular de continuidad

Variable	Descripción	Valores y códigos especiales
area_conocimiento	Área MINEDUC (adaptación CINE-UNESCO 1997)	Diez áreas
area_generica	Área genérica definida por el SIES	Texto
cine_f_13_area / cine_f_13_subarea	Clasificación CINE-F 2013 (UNESCO/OCDE)	Estándar internacional

Anexo B. Columnas descartadas y motivo del descarte

Columna	Motivo del descarte
nombre_titulo	Texto libre de alta cardinalidad; no aporta al análisis agregado.
nombre_grado	Vacío en carreras técnicas; redundante con nivel_carrera_1.
tipo_inst_3	Desagregación de tipo_inst_2 sin uso en las preguntas planteadas.
anio_ing_carr_act	Refiere a convalidación; el SIES indica usar la carrera de origen.
sem_ing_carr_act	Ídem anterior.
cod_sede / nomb_sede	El análisis territorial se realiza a nivel de comuna y región.
version	Metadato administrativo del plan, sin valor analítico.
cine_f_97_area / cine_f_97_subarea	Clasificación CINE-F 1997, superada por CINE-F 2013.

Anexo C. Salida completa de las pruebas automatizadas

===== test session starts =====
collecting ... collected 22 items
tests/test_pipeline.py::test_duracion_real_caso_normal PASSED [4%]
tests/test_pipeline.py::test_sobreduracion_y_categoria PASSED [9%]
tests/test_pipeline.py::test_edad_descuenta_mes_no_cumplido PASSED [13%]
tests/test_pipeline.py::test_edad_cuando_aun_no_cumple_anios PASSED [18%]
tests/test_pipeline.py::test_semestre_de_titulacion_según_mes PASSED [22%]
tests/test_pipeline.py::test_duracion_minima_es_uno PASSED [27%]
tests/test_pipeline.py::test_clasificacion_en_los_bordes PASSED [31%]
tests/test_pipeline.py::test_sentinelas_se_convierten_en_na PASSED [36%]
tests/test_pipeline.py::test_normalizacion_de_texto_respetar_nombres_propios PASSED [40%]
tests/test_pipeline.py::test_duplicados_sin_mrun_no_se_colapsan PASSED [45%]
tests/test_pipeline.py::test_duplicado_exacto_se_elimina PASSED [50%]
tests/test_pipeline.py::test_duracion_teorica_cero_no_divide_por_cero PASSED [54%]
tests/test_pipeline.py::test_registro_sin_fecha_nacimiento_se_marca_atipico PASSED [59%]
tests/test_pipeline.py::test_archivos_faltantes_lanza_excepcion PASSED [63%]
tests/test_pipeline.py::test_cargar_consolidado_inexistente PASSED [68%]
tests/test_pipeline.py::test_validador_detecta_dataset_corrupto PASSED [72%]
tests/test_pipeline.py::test_validador_aprueba_dataset_correcto PASSED [77%]
tests/test_pipeline.py::test_estado_antes_de_ejecutar_lanza_error PASSED [81%]
tests/test_pipeline.py::test_regla_con_excepcion_se_reporta_como_falla PASSED [86%]

```
tests/test_pipeline.py::test_tabla_agregada_respeto_minimo_de_casos PASSED [ 90%]
tests/test_pipeline.py::test_formato_numerico_chileno PASSED [ 95%]
tests/test_pipeline.py::test_configuracion_expone_versiones PASSED [100%]

===== 22 passed in 1.68s =====
```

Anexo D. Contribuciones por integrante

Salida de git shortlog -sn --all sobre el repositorio del proyecto. Cada integrante debe configurar su identidad de Git para que sus commits queden correctamente atribuidos.

```
15 Sebastian Antunez
```

Anexo E. Instrucciones de reproducción

Reproducción del proyecto de principio a fin

```
# 1. Clonar el repositorio
git clone «URL del repositorio»
cd proyecto-titulados

# 2. Crear el entorno virtual e instalar las dependencias
python -m venv .env
.\.env\Scripts\Activate.ps1
pip install -r requirements.txt

# 3. Descargar los seis CSV del SIES y dejarlos en data/raw/
# (o definir la variable de entorno TITULADOS_RAW_DIR)

# 4. Verificar el entorno y ejecutar las pruebas
python -c "from src import config; print(config.describir_entorno())"
python -m pytest tests/ -v

# 5. Ejecutar el pipeline completo
python -m src.pipeline

# 6. Abrir los notebooks en orden: F1, F2_1, F2_2, F2_3
jupyter lab
```

Tiempo aproximado de la primera ejecución completa: entre cuatro y seis minutos, de los cuales unos veinticinco segundos corresponden a la consolidación de los 955 MB de archivos originales.