



Facultad de Ingeniería

Magíster en Ciencia de Datos e Inteligencia Artificial

**SOBREDURACIÓN EN LA TITULACIÓN DE LA EDUCACIÓN SUPERIOR  
CHILENA (2020-2025)**

Informe final integrador — Fase 4: análisis, reproducibilidad y comunicación de  
resultados

Informe final presentado para la asignatura Programación para la Ciencia de Datos  
(202682.1927)

**Autor:**

Sebastian Antunez Noguera

**Profesor:**

Omar Salinas

Santiago, Chile

4 de octubre de 2026

## Ficha del trabajo

| Antecedente           | Detalle                                                                                                         |
|-----------------------|-----------------------------------------------------------------------------------------------------------------|
| Asignatura            | Programación para la Ciencia de Datos (202682.1927)                                                             |
| Programa              | Magíster en Ciencia de Datos e Inteligencia Artificial                                                          |
| Profesor              | Omar Salinas                                                                                                    |
| Autor                 | Sebastian Antunez Noguera (trabajo individual)                                                                  |
| Entrega               | Sumativa 3 — Proyecto final integrador, Fase 4                                                                  |
| Repositorio           | <a href="https://github.com/santunez75/proyecto-titulados">https://github.com/santunez75/proyecto-titulados</a> |
| Notebooks             | F1, F2 (tres), F3 y F4: seis notebooks ejecutados de corrido                                                    |
| Fuente de datos       | SIES, Titulados de Educación Superior 2020-2025 (6 archivos CSV, 955 MB)                                        |
| Conjunto analítico    | 1.246.760 titulados de pregrado, 47 variables                                                                   |
| Entorno               | Python 3.14.7 · pandas 3.0.5 · NumPy 2.5.3 · Windows 11                                                         |
| Pruebas automatizadas | 73 (22 del pipeline de F2 + 51 del núcleo de F3), todas aprobadas                                               |
| Reglas de validación  | 9, todas aprobadas                                                                                              |

*Todas las cifras, tablas y figuras de este informe fueron generadas por los notebooks del repositorio y son reproducibles ejecutándolos. Sus salidas quedan en reports/tables/ y reports/figures/, y cada afirmación puede rastrearse hasta el archivo que la respalda.*

## Índice

Para actualizar el índice en Word: clic en la tabla y F9, o clic derecho → Actualizar campos.

|                                                                           |    |
|---------------------------------------------------------------------------|----|
| 1. Introducción y contextualización .....                                 | 5  |
| 2. Definición de la problemática y objetivos .....                        | 6  |
| 2.1 Problemática y pregunta técnica .....                                 | 6  |
| 2.2 Objetivos .....                                                       | 6  |
| 2.3 Alcance, restricciones y supuestos.....                               | 7  |
| 3. Metodología del desarrollo técnico.....                                | 8  |
| 3.1 Herramientas del ecosistema científico de Python .....                | 8  |
| 3.2 Reproducibilidad técnica .....                                        | 9  |
| 3.3 Control de versiones .....                                            | 10 |
| 3.4 Fase 1 — Definición del problema y entorno .....                      | 11 |
| 3.5 Fase 2 — Preprocesamiento y transformación del dataset.....           | 11 |
| La transformación central: reconstruir la duración real.....              | 12 |
| 3.6 Fase 3 — Núcleo algorítmico, eficiencia y orientación a objetos ..... | 12 |
| Algoritmos implementados y verificados .....                              | 12 |
| Mediciones de eficiencia.....                                             | 13 |
| Programación orientada a objetos .....                                    | 15 |
| 3.7 Arquitectura del código.....                                          | 16 |
| 3.8 Validación técnica y verificación del código .....                    | 17 |
| Nivel 1: corrección contra referencias independientes .....               | 17 |
| Nivel 2: pruebas automatizadas.....                                       | 17 |
| Nivel 3: reglas de coherencia del dominio.....                            | 18 |
| Nivel 4: ejecución de extremo a extremo .....                             | 19 |
| 4. Resultados.....                                                        | 20 |
| 4.1 Panorama general.....                                                 | 20 |
| 4.2 La magnitud del rezago (OE4).....                                     | 21 |
| 4.3 Dónde se concentra el rezago (OE5) .....                              | 22 |
| La brecha de género resiste la estratificación .....                      | 23 |
| 4.4 La evolución temporal y sus límites (OE6).....                        | 24 |
| 4.5 El sesgo que limita la lectura longitudinal .....                     | 25 |
| 4.6 Otros cortes examinados.....                                          | 26 |
| 4.7 Modelación desde primeros principios.....                             | 26 |
| 4.8 El relato de los hallazgos.....                                       | 28 |
| 5. Discusión .....                                                        | 29 |
| 5.1 Contraste con las hipótesis iniciales .....                           | 29 |

|                                                                    |    |
|--------------------------------------------------------------------|----|
| 5.2 Limitaciones y riesgos .....                                   | 29 |
| 5.3 Relación entre las fases y decisiones determinantes .....      | 30 |
| 6. Conclusiones .....                                              | 31 |
| 6.1 Hallazgos sustantivos .....                                    | 31 |
| 6.2 Aprendizajes técnicos .....                                    | 31 |
| 6.3 Mejoras propuestas, basadas en la evidencia del proyecto ..... | 32 |
| 6.4 Comunicación de resultados .....                               | 32 |
| 7. Trazabilidad de mejoras .....                                   | 33 |
| 8. Repositorio y notebooks .....                                   | 34 |
| 8.1 Estructura del repositorio .....                               | 34 |
| 8.2 Notebooks del proyecto .....                                   | 34 |
| 9. Referencias .....                                               | 35 |
| Bibliografía docente .....                                         | 35 |
| Fuente de datos .....                                              | 35 |
| Documentación técnica oficial .....                                | 35 |
| Bibliografía complementaria .....                                  | 36 |
| Anexos .....                                                       | 37 |
| Anexo A. Salida completa de las pruebas automatizadas .....        | 37 |
| Anexo B. Historial completo de commits .....                       | 38 |
| Anexo C. Contribuciones y ramas .....                              | 39 |

## 1. Introducción y contextualización

El sistema de educación superior chileno declara, para cada carrera y cada institución, una duración teórica: el número de semestres que el plan de estudios compromete con el estudiante. Esa cifra orienta decisiones concretas —cuánto financiamiento solicitar, cuántos años de arancel prever, cuándo se espera entrar al mercado laboral— y es la base sobre la que se calculan la duración de las becas y los créditos estatales.

El sistema no publica, en cambio, cuánto tardan efectivamente los estudiantes en titularse. La diferencia entre ambas magnitudes, que este proyecto denomina sobreduración, no existe como variable en ningún registro oficial. Su ausencia no es menor: cada semestre adicional representa arancel pagado, financiamiento consumido e ingresos laborales postergados, tanto para la familia como para el Estado que subsidia la matrícula.

El Servicio de Información de Educación Superior (SIES) publica anualmente la base de Titulados de Educación Superior, con el detalle de cada proceso de titulación del país. Esa base contiene el año y semestre de ingreso a la carrera de origen, la fecha de obtención del título y la duración declarada del plan. Con esos tres elementos la sobreduración puede reconstruirse: es lo que hace este proyecto.

La relevancia del problema es doble. Para la política pública, dimensionar el rezago y localizar dónde se concentra permite focalizar programas de acompañamiento y revisar planes de estudio cuya duración declarada resulta sistemáticamente irrealizable. Para el estudiante y su familia, es la diferencia entre una expectativa informada y una proyección que la evidencia contradice.

Este informe cierra un proyecto desarrollado en cuatro fases, cada una construida sobre la anterior. La Fase 1 definió el problema y levantó un entorno reproducible, la Fase 2 construyó el pipeline que convierte 955 MB de archivos crudos en un conjunto analítico validado, en la Fase 3 implementó desde primeros principios el núcleo algorítmico, algoritmos, mediciones de complejidad, modelo de dominio orientado a objetos y modelos predictivos. Finalmente, en la Fase 4, se documenta, se ejecuta de extremo a extremo, se producen los resultados finales, se discute y se comunica.

El propósito general del trabajo es, por tanto, responder con evidencia a una pregunta sustantiva sobre el sistema educativo chileno y hacerlo con un desarrollo técnico íntegramente reproducible, trazable y verificable por terceros.

## 2. Definición de la problemática y objetivos

### 2.1 Problemática y pregunta técnica

El hallazgo que delimitó el proyecto apareció al leer el esquema de registro oficial del SIES. Las tres columnas que parecían contener la respuesta, `dur_estudio_carr`, `dur_proceso_tit` y `dur_total_carr`, no registran lo que el estudiante tardó, sino lo que el plan declara. Son un atributo de la carrera, no del estudiante. La duración real no está en la base.

**Pregunta técnica que guía el proyecto.** ¿Es posible reconstruir la duración real de la titulación a partir de los registros administrativos disponibles y, con esa variable derivada, caracterizar la magnitud y la distribución del rezago en la educación superior chilena?

La pregunta es técnica antes que sustantiva: su respuesta depende de que la reconstrucción sea correcta, verificable y defendible. De ahí que buena parte del esfuerzo del proyecto se haya destinado a validar esa variable y no solo a describirla.

### 2.2 Objetivos

**Objetivo general.** Construir, validar y analizar un indicador de sobreduración en la titulación de pregrado en Chile a partir de los registros del SIES 2020-2025, mediante un desarrollo en Python íntegramente reproducible y versionado.

**Objetivos específicos.** Los tres primeros son instrumentales: producen el instrumento. Los tres últimos son analíticos y cada uno tiene su figura en el capítulo 4.

1. Consolidar los seis archivos anuales del SIES en un único conjunto analítico, resolviendo los códigos centinela, los duplicados y las inconsistencias de codificación documentadas por la fuente.
2. Reconstruir la duración real de cada trayectoria y derivar de ella la sobreduración, el índice de duración y una categorización del rezago, dejando registro auditable de cada decisión.
3. Implementar desde primeros principios los algoritmos centrales del análisis, medir su complejidad con métodos formales, organizar el dominio con programación orientada a objetos y garantizar la reproducibilidad del conjunto.
4. Dimensionar la magnitud del rezago en el sistema de educación superior chileno.
5. Identificar qué factores institucionales y demográficos se asocian a un mayor rezago.

6. Caracterizar la evolución temporal del rezago y delimitar hasta dónde la fuente permite leerla.

**Tabla 1.** Correspondencia entre objetivos analíticos y figuras

| Objetivo específico                                    | Figura que lo responde                      | Apartado |
|--------------------------------------------------------|---------------------------------------------|----------|
| OE4 · Dimensionar la magnitud del rezago               | Figura 1 — distribución de la sobreduración | 4.2      |
| OE5 · Identificar qué factores se asocian al rezago    | Figura 2 — sobreduración por área           | 4.3      |
| OE6 · Caracterizar la evolución y delimitar su lectura | Figura 3 — serie semestral                  | 4.4      |

Los objetivos instrumentales no tienen figura porque no formulan una pregunta, producen las condiciones para formularla. Su evidencia son el repositorio, las pruebas automatizadas y las mediciones de eficiencia del apartado 3.

## 2.3 Alcance, restricciones y supuestos

**Tabla 2.** Delimitación del estudio

| Dimensión          | Definición adoptada                                                          | Fundamento                                                               |
|--------------------|------------------------------------------------------------------------------|--------------------------------------------------------------------------|
| Población          | Titulados de pregrado del sistema chileno                                    | Posgrado y postítulo no son comparables en duración teórica              |
| Período            | Procesos de titulación 2020-2025 (más el parcial 2026-S1)                    | Cobertura completa de los archivos publicados por el SIES                |
| Unidad de análisis | El proceso de titulación, no la persona                                      | Un estudiante con dos títulos aparece dos veces, por diseño de la fuente |
| Variable objetivo  | $\text{sobreduracion\_sem} = \text{duración real} - \text{duración teórica}$ | Derivada; no existe en la fuente                                         |
| Fuera de alcance   | Deserción, rendimiento académico, costo monetario                            | La base contiene únicamente a quienes se titularon                       |

Restricciones:

- La base registra únicamente titulados. Quien abandonó no aparece, de modo que el rezago medido es el de los que llegaron a egresar.
- El semestre de titulación se deriva del mes: hasta julio se asigna al primer semestre, de agosto en adelante al segundo. La fuente no entrega el semestre de forma directa.
- Las duraciones teóricas las reporta cada institución y no están auditadas centralmente.

- Los datos crudos (955 MB) no se versionan en el repositorio por límites de tamaño; se distribuye una muestra de 5.000 registros que permite ejecutar todo el flujo.

Supuestos:

- La trayectoria entre el ingreso y la titulación se supone continua. La fuente no informa congelamientos, de modo que un semestre suspendido se contabiliza como tiempo transcurrido.
- El año y semestre de ingreso a la carrera de origen identifican correctamente el inicio de la trayectoria conducente al título obtenido.
- La duración teórica declarada es la vigente para la cohorte del estudiante; los cambios de malla dentro del período no son observables.

### 3. Metodología del desarrollo técnico

Esta sección describe cómo se construyó el proyecto: las herramientas empleadas, las decisiones técnicas de cada fase y la forma en que se garantizó que los resultados puedan reproducirse y auditarse.

#### 3.1 Herramientas del ecosistema científico de Python

**Tabla 3.** Herramientas utilizadas y su función en el proyecto

| Herramienta          | Versión         | Función en el proyecto                                                                                     |
|----------------------|-----------------|------------------------------------------------------------------------------------------------------------|
| pandas               | 3.0.5           | Lectura por bloques de los CSV, tipos anulables, agregaciones y tablas de resultados                       |
| NumPy                | 2.5.3           | Álgebra de matrices en los modelos, operaciones vectorizadas, ajuste log-log de las curvas de escalamiento |
| PyArrow              | 25.0.1          | Motor Parquet: el consolidado de 1,7 millones de filas se escribe y relee en segundos                      |
| Matplotlib / seaborn | 3.11.1 / 0.13.2 | Todas las figuras, con estilo unificado definido en src/viz.py                                             |
| JupyterLab           | 4.6.3           | Entorno de los seis notebooks del proyecto                                                                 |
| nbconvert            | 7.17.1          | Ejecución de los notebooks de corrido, sin intervención manual                                             |
| pytest               | 9.1.1           | 73 pruebas automatizadas de casos normales, límite y excepciones                                           |
| timeit / tracemalloc | estándar        | Mediciones formales de tiempo y de pico de memoria                                                         |
| Git y GitHub         | —               | Control de versiones, ramas por fase y trazabilidad del desarrollo                                         |

La integración entre herramientas es coherente de extremo a extremo: los notebooks importan el paquete `src/`, que a su vez usa `pandas` y `NumPy`. Las figuras y tablas que producen se escriben en `reports/` y desde ahí las lee este informe. Ningún número de este documento se transcribió a mano.

## 3.2 Reproducibilidad técnica

El proyecto se ejecuta en un entorno virtual con dependencias fijadas por versión exacta. Cualquier equipo con Python 3.14 reproduce el análisis con cuatro comandos.

### Instalación y ejecución completas del proyecto

|                                                                                                |
|------------------------------------------------------------------------------------------------|
| <code>git clone https://github.com/santunez75/proyecto-titulados.git</code>                    |
| <code>cd proyecto-titulados</code>                                                             |
| <code>python -m venv .venv</code>                                                              |
| <code>.venv\Scripts\python.exe -m pip install -r requirements.txt</code>                       |
| <code>.venv\Scripts\python.exe -m pytest tests/ -q</code> # 73 pruebas, sin datos externos     |
| <code>.venv\Scripts\python.exe -m src.pipeline</code> # regenera el dataset (requiere los CSV) |
| <code>.venv\Scripts\python.exe -m jupyter lab</code> # ejecuta los notebooks                   |

Tres decisiones sostienen esa reproducibilidad, y las tres se adoptaron después de detectar un fallo concreto al reproducir el proyecto en un segundo equipo:

1. Versiones fijadas con `==` en `requirements.txt`. El notebook de la Fase 4 compara las versiones instaladas contra las declaradas y reporta cuántas coinciden: si alguna difiere, quien ejecute el proyecto lo sabe antes de interpretar los resultados.
2. Degradación controlada de la carga de datos. Si el Parquet completo no existe, `cargar_datos()` usa la muestra versionada de 5.000 registros y lo informa por pantalla. El notebook corre en un equipo sin los CSV originales, en lugar de fallar.
3. Pruebas ejecutadas con el intérprete del entorno virtual, no con el del kernel. Un kernel de Jupyter distinto al `.venv` hacía fallar la celda de pruebas sin mostrar la causa, porque el error viajaba por `stderr`. Ahora la celda apunta al intérprete correcto e imprime `stderr` cuando el código de salida no es cero.

Las tres comparten un criterio que atraviesa el proyecto: convertir un fallo silencioso en un comportamiento explícito. Un error que se ve es un error que se corrige; uno que no se ve contamina resultados.

### 3.3 Control de versiones

El repositorio acumula 45 commits distribuidos a lo largo de las cuatro fases. Los mensajes siguen la convención de commits semánticos (feat, fix, perf, test, docs, chore) y explican qué se hizo y por qué, no solo qué archivo cambió.

El trabajo de las Fases 2 y 3 se desarrolló en ramas propias, fase-2/pipeline-datos y fase-3/nucleo-algoritmico, que se integraron a main mediante fusiones explícitas sin avance rápido, de modo que el punto de integración queda registrado en el historial y la estructura del desarrollo puede reconstruirse.

**Tabla 4.** Commits más recientes del repositorio (36 en total)

| Hash    | Fecha      | Mensaje                                                                     |
|---------|------------|-----------------------------------------------------------------------------|
| 21cfbb9 | 2026-09-27 | feat(f4): notebook del reporte analitico integrador con cuatro figuras      |
| 7538f5c | 2026-09-24 | chore(f3): re-ejecuta los notebooks en el entorno local y actualiza salidas |
| b5523ad | 2026-09-24 | docs(f3): versión final del informe                                         |
| b62d36a | 2026-09-21 | docs(f3): informe y evidencias alineados con el historial definitivo        |
| 9062995 | 2026-09-21 | merge: integra la rama fase-3/nucleo-algoritmico en main                    |
| 58cb930 | 2026-09-19 | docs(f3): actualiza el informe y las evidencias con el historial definitivo |
| b769379 | 2026-09-19 | docs(f3): agrega el PDF del informe con la fecha de entrega                 |
| d10b470 | 2026-09-19 | docs(f3): Primer Informe F3                                                 |
| 6d348f8 | 2026-09-19 | docs(f3): informe tecnico de la Fase 3 y evidencias de ejecucion            |
| b8770f5 | 2026-09-19 | docs(f3): notebook del nucleo algoritmico ejecutado de corrido              |
| d6df25e | 2026-09-19 | test(nucleo): 51 pruebas de casos normales, limite y excepciones            |
| 40be4d9 | 2026-09-19 | feat(nucleo): preparacion, modelos por descenso de gradiente y fachada      |

#### git log --oneline --graph: ramas y puntos de integración

|                                                                                       |
|---------------------------------------------------------------------------------------|
| * 21cfbb9 feat(f4): notebook del reporte analitico integrador con cuatro figuras      |
| * 7538f5c chore(f3): re-ejecuta los notebooks en el entorno local y actualiza salidas |
| * b5523ad docs(f3): versión final del informe                                         |
| * b62d36a docs(f3): informe y evidencias alineados con el historial definitivo        |
| * 9062995 merge: integra la rama fase-3/nucleo-algoritmico en main                    |
| \                                                                                     |
| * 58cb930 docs(f3): actualiza el informe y las evidencias con el historial definitivo |
| * b769379 docs(f3): agrega el PDF del informe con la fecha de entrega                 |
| * d10b470 docs(f3): Primer Informe F3                                                 |
| * 6d348f8 docs(f3): informe tecnico de la Fase 3 y evidencias de ejecucion            |
| * b8770f5 docs(f3): notebook del nucleo algoritmico ejecutado de corrido              |
| * d6df25e test(nucleo): 51 pruebas de casos normales, limite y excepciones            |

Contribuciones. El proyecto es de autoría individual: la totalidad de los commits corresponde al autor. Durante el desarrollo el historial registró dos identidades de Git “Sebastian Antunez” y “santunez75”, originadas en que uno de los dos equipos quedó configurado con

el nombre de usuario de GitHub. Ambas comparten el correo institucional. El repositorio incluye un archivo .mailmap que las unifica, de modo que git shortlog, git blame y las estadísticas de GitHub informan un único autor. Sin ese archivo, cualquier herramienta que contabilice contribuyentes reportaría dos personas donde hay una. El detalle está en el Anexo C.

### 3.4 Fase 1 — Definición del problema y entorno

La Fase 1 estableció tres cosas que condicionaron todo lo demás: la pregunta técnica, el entorno reproducible y la organización modular del código. La decisión de separar el código en módulos con una responsabilidad cada uno, en lugar de escribirlo dentro de los notebooks, permitió que el proyecto creciera de 5 a 16 módulos sin reescrituras.

### 3.5 Fase 2 — Preprocesamiento y transformación del dataset

El pipeline de la Fase 2 convierte seis CSV heterogéneos en un conjunto analítico validado. Se ejecuta con un comando y deja bitácora de cada paso. La tabla documenta las ocho etapas, su efecto cuantificado y la justificación técnica de cada una.

**Tabla 5.** Pipeline de preprocesamiento: tratamiento, efecto y justificación

| Paso                   | Tratamiento                                                                                | Efecto                   | Justificación técnica                                                                                                            |
|------------------------|--------------------------------------------------------------------------------------------|--------------------------|----------------------------------------------------------------------------------------------------------------------------------|
| Ingesta                | Lectura por bloques de 6 CSV con dtypes declarados y validación de esquema                 | 1.710.167 filas          | Declarar los tipos evita inferencias erróneas y reduce el uso de memoria a la mitad                                              |
| Códigos centinela      | 9995/9998/9999/1900, 19000101 y semestre 0 convertidos a nulos explícitos                  | 62.492 en año de ingreso | Procesados como números producirían duraciones imposibles; hacerlos visibles precede a cualquier decisión                        |
| Normalización de texto | 18 columnas categóricas homogeneizadas sobre su catálogo de valores únicos                 | 8,6 millones de celdas   | Evita categorías duplicadas por capitalización; operar sobre el catálogo reduce el costo de 1,7 millones de cadenas a unos miles |
| Restricción a pregrado | Filtro nivel_global == Pregrado                                                            | 398.391 excluidos        | Posgrado y postítulo no son comparables en duración teórica                                                                      |
| Duplicados             | Clave estudiante + carrera + fecha de titulación; filas sin identificador fuera del cotejo | 72 eliminados            | Pandas trata dos nulos como iguales; incluirlos colapsaría estudiantes distintos                                                 |
| Descarte sin insumos   | Filas sin año o semestre de ingreso utilizable                                             | 61.825 (4,7 %)           | Imputar el inicio de la trayectoria equivaldría a inventar la variable objetivo                                                  |

| Paso                 | Tratamiento                                                                           | Efecto            | Justificación técnica                                                                                 |
|----------------------|---------------------------------------------------------------------------------------|-------------------|-------------------------------------------------------------------------------------------------------|
| Derivación y casting | Duración real, sobreduración, índice, edad y categoría de rezago en enteros anulables | 1.246.760 finales | Enteros exactos en lugar de coma flotante: sin errores de redondeo en las comparaciones               |
| Atípicos             | Fuera de [1, 40] semestres o edad fuera de [15, 90], marcados con un indicador        | 3.119 (0,25 %)    | Umbrales parametrizados en config.py; marcar en vez de eliminar deja la decisión visible y reversible |

Retención final: 1.246.760 de 1.710.167 filas, un 72,9 %. Cada exclusión está justificada y cuantificada en la bitácora de limpieza que el pipeline escribe en `reports/tables/bitacora_limpieza.csv`.

## La transformación central: reconstruir la duración real

`src/transformacion.py` — la derivación sobre la que descansa todo el análisis

```
# La duracion real no existe en la fuente: se deriva del ingreso y la titulacion.
# El semestre se infiere del mes porque la base no lo entrega directamente.
semestre_titulo = np.where(mes_titulo <= 7, 1, 2)

duracion_real_sem = (anio_titulo - anio_ing_carr_ori) * 2 \
    + (semestre_titulo - sem_ing_carr_ori) + 1

sobreduracion_sem = duracion_real_sem - dur_total_carr # variable objetivo
indice_duracion = duracion_real_sem / dur_total_carr # razon, comparable entre carreras
```

El «+1» no es un ajuste arbitrario, un estudiante que ingresa y se titula en el mismo semestre cursó un semestre, no cero. La coherencia aritmética de esta derivación se comprueba como regla de validación sobre el dataset completo.

## 3.6 Fase 3 — Núcleo algorítmico, eficiencia y orientación a objetos

La Fase 2 resolvió el problema con pandas. La Fase 3 preguntó qué hay debajo: implementó desde primeros principios los algoritmos centrales del análisis, midió su costo y organizó el dominio con programación orientada a objetos.

## Algoritmos implementados y verificados

`src/nucleo/algoritmos.py` — agregación iterativa y selección recursiva

```
def agrupar_media(claves, valores):
    """Media por clave en una sola pasada. Tiempo O(n), espacio O(k)."""
    if len(claves) != len(valores):
        raise ValueError("claves y valores deben tener el mismo largo")
    suma, cuenta = {}, {} # dos acumuladores por grupo
    for clave, valor in zip(claves, valores): # una unica pasada sobre los datos
        suma[clave] = suma.get(clave, 0.0) + valor
```

```

    cuenta[clave] = cuenta.get(clave, 0) + 1
    return {clave: suma[clave] / cuenta[clave] for clave in suma}

def _quickselect(datos, k, rng):
    if len(datos) == 1:
        # caso base
        return datos[0]
    pivote = datos[rng.randrange(len(datos))] # pivote aleatorio: O(n) esperado
    menores = [x for x in datos if x < pivote] # tres particiones: la variable
    iguales = [x for x in datos if x == pivote] # tiene miles de valores repetidos
    mayores = [x for x in datos if x > pivote]
    if k < len(menores):
        # recurre solo donde esta la posicion
        return _quickselect(menores, k, rng)
    if k < len(menores) + len(iguales):
        return pivote
    return _quickselect(mayores, k - len(menores) - len(iguales), rng)

```

Cada algoritmo se verificó contra una referencia independiente sobre los datos reales antes de medir su eficiencia: la agregación contra groupby de pandas, el ordenamiento contra sorted, la mediana y el percentil contra NumPy, y el conteo por umbral contra value\_counts. Medir un algoritmo incorrecto no tiene sentido.

### Mediciones de eficiencia

Las mediciones usan timeit.repeat y reportan el mínimo de las repeticiones: el ruido del sistema operativo solo puede sumar tiempo, de modo que el mínimo es el mejor estimador del costo intrínseco (Python Software Foundation, 2025a). La memoria se mide con tracemalloc como pico de asignación (Python Software Foundation, 2025b). Además del tamaño fijo, cada algoritmo se mide para tamaños crecientes y se ajusta una recta en escala log-log cuya pendiente es el exponente empírico de crecimiento (Cormen et al., 2022).

**Tabla 6.** Tiempo y memoria por implementación (n = 200.000 elementos)

| Operación    | Implementación               | Tiempo   | Memoria (KB) | Razón |
|--------------|------------------------------|----------|--------------|-------|
| agregación   | agrupar_medio O(n)           | 0,0480 s | 0,7          | 5,7×  |
| agregación   | agrupar_medio_ingenua O(n·k) | 0,0860 s | 705,5        | 10,2× |
| agregación   | pandas groupby               | 0,0084 s | 3132,6       | 1,0×  |
| ordenamiento | numpy.sort                   | 0,0087 s | 3127,8       | 1,0×  |
| ordenamiento | sorted (Timsort en C)        | 0,0119 s | 2343,6       | 1,4×  |
| ordenamiento | ordenar_merge O(n log n)     | 0,5891 s | 3250,9       | 68,1× |
| mediana      | numpy.median                 | 0,0094 s | 3128,2       | 1,0×  |
| mediana      | mediana_ordenando O(n log n) | 0,0121 s | 2343,6       | 1,3×  |
| mediana      | quickselect O(n)             | 0,0528 s | 4422,2       | 5,6×  |
| búsqueda     | busqueda_binaria O(log n)    | 1,0 μs   | 0,0          | 1,0×  |

| Operación | Implementación         | Tiempo   | Memoria (KB) | Razón   |
|-----------|------------------------|----------|--------------|---------|
| búsqueda  | busqueda_lineal $O(n)$ | 0,0063 s | 0,1          | 6344,0× |

La razón indica cuántas veces más lenta es cada implementación respecto de la mejor de su operación. La inserción  $O(n^2)$  se midió aparte con  $n = 3.000$ .

**Tabla 7.** Cota teórica frente a exponente empírico

| Algoritmo         | Cota teórica  | Exponente empírico | Rango de n medido |
|-------------------|---------------|--------------------|-------------------|
| agrupar_media     | $O(n)$        | 0,96               | 20.000 – 640.000  |
| ordenar_merge     | $O(n \log n)$ | 1,08               | 20.000 – 640.000  |
| quickselect       | $O(n)$        | 1,22               | 20.000 – 640.000  |
| sorted            | (C)           | 1,03               | 20.000 – 640.000  |
| ordenar_insercion | $O(n^2)$      | 2,00               | 500 – 4.000       |

Las decisiones de optimización derivadas de estas mediciones son cuatro, y todas están implementadas en el código:

1. La agregación ingenua  $O(n \cdot k)$  se reemplazó por una de una sola pasada  $O(n)$ : 1,9 veces más rápida con diez grupos y 860 veces más económica en memoria (0,7 KB frente a 603,9 KB), porque no materializa una sublista por grupo.
2. Los conteos por umbral se resuelven con dos búsquedas binarias recursivas sobre una copia ordenada:  $O(\log n)$  por consulta, 6.516 veces más rápido que el recorrido lineal.
3. Los totales del árbol jerárquico se memorizan, lo que evita recorrer el subárbol en cada consulta.
4. pandas y NumPy se conservan para las operaciones masivas. A igual complejidad su constante es uno o dos órdenes de magnitud menor por estar escritos en C: sorted y numpy.sort superan a merge sort entre 48 y 66 veces. Los algoritmos propios se reservan para los casos en que su orden es estrictamente mejor y no existe equivalente en C sobre objetos.

Una excepción resultó instructiva: quickselect es  $O(n)$  en número de comparaciones, pero su exponente empírico es 1,22 porque cada nivel de recursión asigna tres listas nuevas. La cota describe el crecimiento, no la constante ni el comportamiento de la memoria. Ese contraste entre teoría y medición es, en sí mismo, un resultado del proyecto.

## Programación orientada a objetos

Las clases del núcleo se diseñaron a partir de una necesidad concreta cada una, y no al revés: encapsulamiento donde hay invariantes que proteger, herencia donde hay comportamiento común real, composición donde la relación es de pertenencia.

### src/nucleo/ — encapsulamiento, polimorfismo y recursión sobre objetos

```
class Titulado:
    __slots__ = ("_mrun", "_duracion_teorica", "_duracion_real", ...) # sin __dict__

    @duracion_real.setter
    def duracion_real(self, valor: int) -> None:
        if int(valor) < config.DURACION_REAL_MIN: # el invariante vive en el objeto
            raise ValueError("la duracion real debe ser >= 1")
        self._duracion_real = int(valor)

    @property
    def sobreduracion(self) -> int: # derivada: nunca inconsistente
        return self._duracion_real - self._duracion_teorica

class Metrica(ABC): # patron Strategy
    @abstractmethod
    def calcular(self, cohorte) -> float: ... # cada subclase aporta la formula

class NodoJerarquia: # patron Composite
    def total(self) -> int: # recursivo y memorizado
        if self._cache_total is None:
            self._cache_total = len(self._titulados) + sum(h.total() for h in
self._hijos.values())
        return self._cache_total
```

**Tabla 8.** Patrones de diseño aplicados, función y alternativa descartada

| Patrón    | Dónde               | Función en la arquitectura                                              | Alternativa descartada                                             |
|-----------|---------------------|-------------------------------------------------------------------------|--------------------------------------------------------------------|
| Strategy  | Metrica y subclases | Indicadores intercambiables sin tocar Cohorte ni la jerarquía           | Un if/elif por métrica dentro de Cohorte                           |
| Composite | NodoJerarquia       | Misma interfaz en hojas y nodos internos; agregación recursiva uniforme | Un groupby distinto por nivel: tres códigos para la misma pregunta |

| Patrón          | Dónde                   | Función en la arquitectura                                                       | Alternativa descartada                                           |
|-----------------|-------------------------|----------------------------------------------------------------------------------|------------------------------------------------------------------|
| Template Method | ModeloGradiente.ajustar | El bucle de optimización se escribe una vez; cada modelo aporta enlace y pérdida | Copiar el bucle en cada modelo: duplicación y divergencia futura |
| Facade          | NucleoAnalitico         | Los notebooks no dependen de los detalles internos de nueve módulos              | Que el notebook coordine cada módulo: alto acoplamiento          |
| Composición     | PreparadorModelacion    | Tiene un escalador y un codificador; los coordina sin heredar de ellos           | Herencia múltiple: relación «es un» incorrecta                   |

### 3.7 Arquitectura del código

El proyecto se organiza en dieciséis módulos agrupados por responsabilidad. La arquitectura se rige por tres criterios verificables en el código, no por convenciones declaradas.

#### Arquitectura del paquete y sentido de las dependencias

|                      |                                                                               |
|----------------------|-------------------------------------------------------------------------------|
| src/                 |                                                                               |
| -- config.py         | Rutas, esquema de datos y parametros (unica fuente de constantes)             |
| -- ingesta.py        | Lectura por bloques de los CSV y consolidacion en Parquet                     |
| -- limpieza.py       | Centinelas, faltantes, duplicados y bitacora auditable                        |
| -- transformacion.py | Duracion real, sobreduracion, indice y categorias de rezago                   |
| -- validacion.py     | Motor de reglas (Regla, ValidadorDataset) reutilizado en F3 y F4              |
| -- viz.py            | Estilo unificado de figuras y formato numerico chileno                        |
| -- pipeline.py       | Orquestador ejecutable de F1-F2                                               |
| \-- nucleo/          | Nucleo algoritmico de la Fase 3                                               |
| -- algoritmos.py     | Agregacion, merge sort, quickselect, busqueda binaria                         |
| -- benchmark.py      | timeit + tracemalloc, curvas, exponente empirico                              |
| -- dominio.py        | Titulado y Cohorte (encapsulamiento, protocolo de secuencia)                  |
| -- metricas.py       | Metrica abstracta y seis subclases (Strategy)                                 |
| -- jerarquia.py      | NodoJerarquia recursivo con memorizacion (Composite)                          |
| -- preparacion.py    | Transformador -> escaladores y one-hot (herencia)                             |
| -- modelos.py        | Regresion lineal y logistica por gradiente (Template Method)                  |
| -- fachada.py        | NucleoAnalitico (Facade): punto de entrada unico                              |
| \-- validacion_f3.py | Reglas de coherencia sobre el motor de la Fase 2                              |
| dependencias:        | fachada -> {dominio, metricas, jerarquia, preparacion, modelos} -> algoritmos |
|                      | benchmark y algoritmos no importan nada del resto del proyecto                |

- **Alta cohesión.** Cada módulo agrupa lo que cambia junto: los algoritmos no saben qué es un titulado; las métricas no saben cómo se construye una cohorte; los modelos no saben de dónde salen las matrices.
- **Bajo acoplamiento.** Las dependencias apuntan en un solo sentido y los módulos se comunican por interfaces pequeñas: una secuencia iterable, una matriz NumPy, una función que devuelve un booleano y un detalle. Ese bajo acoplamiento es lo que permitió probar cada módulo por separado con datos contruidos en memoria, sin necesidad de los archivos del SIES.
- **Extensibilidad.** Agregar un nivel a la jerarquía es cambiar una tupla de nombres; agregar un modelo es escribir dos ganchos; agregar una regla de validación es una línea. Ninguna de esas extensiones exige modificar código existente.

La recursividad se aplica donde el problema es recursivo por naturaleza y no como ejercicio: en el ordenamiento por mezcla, en la selección del k-ésimo menor, en las búsquedas binarias y en el árbol jerárquico, donde insertar, contar y recorrer se definen sobre un nodo en términos de sus hijos. En todos los casos la profundidad está acotada por  $O(\log n)$ , 21 niveles para 1,25 millones de elementos, y el caso base está explícito en las primeras líneas.

### 3.8 Validación técnica y verificación del código

La verificación opera en cuatro niveles, todos con evidencia registrada en el repositorio.

#### Nivel 1: corrección contra referencias independientes

Cada algoritmo propio se contrasta con una implementación externa sobre los datos reales. Las comparaciones son aserciones dentro de los notebooks: una discrepancia detiene la ejecución en lugar de producir un resultado silenciosamente incorrecto.

#### Nivel 2: pruebas automatizadas

**Tabla 9.** Cobertura de la suite de pruebas

| Módulo        | Casos normales                                                    | Casos límite                                                   | Excepciones                                          |
|---------------|-------------------------------------------------------------------|----------------------------------------------------------------|------------------------------------------------------|
| pipeline (F2) | Centinelas, duplicados, derivación, reglas de validación          | Dataset de una fila; columnas ausentes                         | Esquema inválido; rutas inexistentes                 |
| algoritmos    | Coincidencia con pandas, sorted y NumPy; estabilidad; no mutación | Secuencia vacía y de un elemento; bordes con valores repetidos | Largos distintos; k fuera de rango; mediana de vacío |

| Módulo                | Casos normales                                                  | Casos límite                               | Excepciones                                                 |
|-----------------------|-----------------------------------------------------------------|--------------------------------------------|-------------------------------------------------------------|
| benchmark             | Exponente $\approx 1$ para lineal y $\approx 2$ para cuadrático | —                                          | Menos de dos tamaños; tamaños iguales                       |
| dominio               | Propiedades derivadas; orden natural; igualdad                  | Cambio de duración recalcula derivadas     | Identidad de solo lectura; setters inválidos                |
| metricas / jerarquia  | Polimorfismo; totales recursivos; descenso por máximo           | Nodo vacío; cache invalidada tras insertar | Cohorte vacía; percentil fuera de rango                     |
| preparacion / modelos | Media 0 y desviación 1; convergencia; pérdida decreciente       | Columna constante; categoría no vista      | Transformar sin ajustar; NaN; divergencia por tasa excesiva |

**Resultado de pytest tests/ -v**

|                                 |
|---------------------------------|
| ===== test session starts ===== |
| ===== 73 passed in 1.65s =====  |
| (salida completa en el Anexo A) |

**Nivel 3: reglas de coherencia del dominio**

El motor de reglas de la Fase 2 se reutiliza sin modificación sobre los artefactos de las Fases 3 y 4; es un caso de reutilización entre fases que la arquitectura modular hizo trivial.

**Tabla 10.** Reglas de validación y resultado

| Regla                   | Comprobación                                                        | Estado |
|-------------------------|---------------------------------------------------------------------|--------|
| cohorte_y_arbol         | La jerarquia contiene exactamente los titulados de la cohorte.      | PASA   |
| hojas_suman_total       | Las hojas del arbol suman el total de la raiz (recursion correcta). | PASA   |
| metrica_composite       | Una metrica via el arbol coincide con la misma via la cohorte.      | PASA   |
| tasa_oportuna_coherente | La tasa de titulacion oportuna sobre objetos coincide con la de F2. | PASA   |
| convergencia_gd         | El descenso de gradiente converge a la solucion cerrada.            | PASA   |
| perdida_decrece         | La perdida final es menor que la inicial.                           | PASA   |
| matrices_modelacion     | Las matrices no tienen NaN y comparten columnas.                    | PASA   |
| metricas_finitas        | Todas las metricas de desempeno son numeros finitos.                | PASA   |
| r2_positivo             | El modelo lineal explica varianza en el conjunto de prueba.         | PASA   |

#### **Nivel 4: ejecución de extremo a extremo**

Los seis notebooks del proyecto se ejecutan de corrido con nbconvert en el entorno declarado, sin errores ni intervención manual. Las evidencias quedan versionadas en informe/evidencias\_f4/ y en reports/, de modo que cada afirmación de este informe puede confirmarse en el repositorio.

## 4. Resultados


Las tres figuras de este capítulo no son una selección estética: cada una responde uno de los objetivos analíticos declarados en 2.2, y las tres están encadenadas como un argumento. El título de cada figura enuncia el hallazgo en lugar de rotular el tema, y cada una se acompaña de cuatro lecturas: qué muestra, qué se infiere, qué límite tiene y qué papel cumple en la secuencia.

### 4.1 Panorama general

**Tabla 11.** Indicadores finales del estudio

| Indicador                          | Valor     | Lectura                                             |
|------------------------------------|-----------|-----------------------------------------------------|
| Titulados de pregrado analizados   | 1.246.760 | Período 2020-2025 más el parcial 2026-S1            |
| Sobreduración media                | 2,76 sem. | El estudiante promedio cursa 2,76 semestres de más  |
| Sobreduración mediana              | 1,0 sem.  | La distancia con la media revela el peso de la cola |
| Índice de duración medio           | 1,43      | Se cursa un 43 % más de tiempo del planificado      |
| Titulación en el plazo teórico     | 19,0 %    | Solo uno de cada cinco egresa en plazo              |
| Rezago severo (más de 4 semestres) | 20,4 %    | Tantos como los que se titulan a tiempo             |
| Titulación anticipada              | 4,1 %     | Convalidaciones y cambios de carrera                |
| Semestres-estudiante en exceso     | 3.551.990 | Costo agregado del rezago en el período             |

## 4.2 La magnitud del rezago (OE4)



Fuente: elaboración propia a partir de SIES, Titulados de Educación Superior 2020-2025 (n = 1.246.760).

**Figura 1.** Solo el 19,0 % se titula en plazo y una proporción equivalente acumula rezago severo. Fuente: elaboración propia a partir de SIES, Titulados de Educación Superior 2020-2025 (n = 1.246.760).


**Qué muestra.** El reparto de la sobreduración entre los 1.246.760 titulados de pregrado del período, con el plazo teórico marcado en cero y la cola de rezago severo, de más de cuatro semestres, destacada en color. La vista se recortó entre -4 y 20 semestres, intervalo que contiene al 99 % de los casos.

**Qué se infiere.** El rezago no es una anomalía sino la norma, cuatro de cada cinco titulados egresan fuera de plazo. La distribución es marcadamente asimétrica y una cola larga arrastra la media (2,76) muy por encima de la mediana (1,0). El grupo con rezago severo (20,4 %) es tan numeroso como el que se titula a tiempo (19,0 %).

**Qué límite tiene.** La figura describe a quienes se titularon: quien abandonó no aparece, de modo que la magnitud está subestimada en la dirección más grave. El recorte del eje deja fuera unos doce mil casos extremos que no alteran la forma, pero sí el promedio.

**Cómo aporta al relato.** Es el movimiento de contexto: establece la magnitud del fenómeno y deja planteada la pregunta que la figura siguiente responde, si ese rezago se reparte de forma pareja o se concentra en algún grupo.

### 4.3 Dónde se concentra el rezago (OE5)



Fuente: elaboración propia a partir de SIES, Titulados de Educación Superior 2020-2025 (n = 1.246.760).

**Figura 2.** Derecho triplica a Educación: 5,77 frente a 1,93 semestres de exceso. Fuente: elaboración propia a partir de SIES, Titulados de Educación Superior 2020-2025 (n = 1.246.760).

**Qué muestra.** La sobreduración media de cada una de las diez áreas de conocimiento, ordenadas de menor a mayor, con el número de titulados junto a cada barra. El eje parte en cero, de modo que la longitud de la barra es proporcional a la magnitud.

**Qué se infiere.** El rezago se distribuye de forma muy desigual: casi cuatro semestres, dos años, separan al área más rezagada de la menos rezagada. El patrón se repite por tipo de institución (universidades 3,32 frente a institutos profesionales 2,05) y por género, donde las mujeres se titulan 0,93 semestres antes en las diez áreas sin excepción.

**Qué límite tiene.** Es una asociación, no una explicación. El área agrupa carreras heterogéneas y su duración teórica declarada puede ser sistemáticamente más optimista en unas que en otras: parte de la diferencia podría ser un artefacto de la declaración y no del comportamiento estudiantil. Todas las medias descansan sobre grupos grandes salvo Ciencias Básicas (13.505 titulados), la única cuya cifra conviene leer con más holgura.

**Cómo aporta al relato.** Es el movimiento de contraste: localiza dónde está la diferencia que la figura anterior dejó planteada y acota el fenómeno a grupos identificables sobre los que se podría intervenir.

## La brecha de género resiste la estratificación


Que las mujeres se titulen antes podría ser un efecto de composición: si estudiaran carreras más cortas, la diferencia no diría nada sobre su trayectoria. El procedimiento para descartar esa confusión es estratificar, es decir, dividir por la variable sospechosa y comprobar si la diferencia persiste dentro de cada estrato.

**Tabla 12.** Sobreduración media por género dentro de cada área de conocimiento

| Área de conocimiento      | Hombres   | Mujeres   | Diferencia |
|---------------------------|-----------|-----------|------------|
| Arte y Arquitectura       | 3,27 sem. | 2,30 sem. | +0,97      |
| Educación                 | 2,63 sem. | 1,75 sem. | +0,88      |
| Derecho                   | 6,14 sem. | 5,48 sem. | +0,66      |
| Ciencias Sociales         | 2,41 sem. | 1,86 sem. | +0,55      |
| Agropecuaria              | 3,87 sem. | 3,35 sem. | +0,52      |
| Salud                     | 2,72 sem. | 2,28 sem. | +0,44      |
| Administración y Comercio | 2,67 sem. | 2,25 sem. | +0,42      |
| Humanidades               | 2,91 sem. | 2,62 sem. | +0,30      |
| Tecnología                | 3,67 sem. | 3,48 sem. | +0,18      |
| Ciencias Básicas          | 4,56 sem. | 4,42 sem. | +0,14      |

La diferencia se mantiene en las diez áreas y en ninguna se invierte. El área queda descartada como variable de confusión, aunque no las que la fuente no registra.

## 4.4 La evolución temporal y sus límites (OE6)



**Figura 3.** El mínimo de 2020 y el máximo de 2021 son el mismo fenómeno: la pandemia desplazó titulaciones. Fuente: elaboración propia a partir de SIES, Titulados de Educación Superior 2020-2025 (n = 1.246.760).

**Qué muestra.** La sobreduración media de cada semestre entre 2020-S1 y 2026-S1 sobre el número de titulaciones de ese semestre. El último periodo lleva trama porque está en curso. El eje vertical izquierdo está recortado y no parte en cero: lo representado es la variación y no la magnitud, y se declara aquí según corresponde en un gráfico de líneas.


**Qué se infiere.** En 2020 se titularon 87.051 personas menos que en 2021 y la sobreduración tocó su mínimo; al año siguiente el volumen se recuperó y la sobreduración alcanzó su máximo. La lectura no es que 2020 fuera un buen año: las titulaciones se postergaron, y quienes debían egresar entonces lo hicieron en 2021 con uno o dos semestres adicionales. El mecanismo es de desplazamiento administrativo, no de deterioro académico.

**Qué límite tiene.** La coincidencia temporal con la pandemia no prueba que la pandemia sea la causa, es una asociación sobre datos observacionales, sin grupo de control. Y el descenso sostenido desde 2024 no puede leerse como una mejora del sistema, por la razón que documenta el apartado siguiente.

**Cómo aporta al relato.** Es el movimiento de resolución: confirma el patrón sobre una evidencia distinta, la dimensión temporal, que las dos figuras anteriores no usaban, y declara explícitamente hasta dónde alcanza la lectura.

### 4.5 El sesgo que limita la lectura longitudinal

La figura siguiente no responde un objetivo: sostiene la limitación declarada en la anterior. Por eso se presenta como figura de apoyo.



Fuente: elaboración propia a partir de SIES, Titulados de Educación Superior 2020-2025 (n = 1.246.760).

**Figura 4.** De las cohortes recientes solo se han titulado los más rápidos: ninguna cohorte está completa.  
Fuente: elaboración propia a partir de SIES, Titulados de Educación Superior 2020-2025.

**Tabla 13.** Cohortes recientes: titulados observados y sobreduración media

| Cohorte de ingreso | Titulados observados | Sobreduración media |
|--------------------|----------------------|---------------------|
| 2014               | 42.853               | 6,77 sem.           |
| 2015               | 70.711               | 5,13 sem.           |
| 2016               | 107.567              | 3,78 sem.           |
| 2017               | 134.348              | 3,08 sem.           |
| 2018               | 191.319              | 2,13 sem.           |
| 2019               | 184.973              | 1,71 sem.           |
| 2020               | 152.516              | 1,34 sem.           |
| 2021               | 128.566              | 1,05 sem.           |
| 2022               | 91.665               | 0,86 sem.           |
| 2023               | 68.826               | 0,47 sem.           |
| 2024               | 10.734               | -0,27 sem.          |
| 2025               | 392                  | -1,99 sem.          |

La sobreduración media cae de forma monótona en las cohortes recientes hasta hacerse negativa. De la cohorte 2024 solo se han titulado los excepcionalmente rápidos, porque son los únicos que alcanzaron a hacerlo, de las cohortes antiguas, quienes aparecen en una base de 2020-2025 son los extremadamente rezagados. Ninguna cohorte está completa y lo están en direcciones opuestas. Es una limitación del diseño de la fuente, no del procesamiento, y por eso las comparaciones longitudinales solo son válidas entre cohortes con horizonte de titulación equivalente.

## 4.6 Otros cortes examinados

Los cortes siguientes se exploraron y se decidió no llevarlos a figura. Declarar qué se descartó, y por qué, es parte del argumento: una figura de más diluye el relato tanto como una de menos lo deja incompleto.

**Tabla 14.** Cortes explorados y decisión adoptada

| Corte                    | Decisión                  | Motivo                                                                                                                                                                                             |
|--------------------------|---------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Modalidad de enseñanza   | Al texto, sin figura      | La modalidad no presencial registra 1,84 semestres frente a 2,86 de la presencial, pero atrae otro perfil de estudiante: la comparación mezcla el efecto de la modalidad con el de quién la elige. |
| Territorio               | Al tablero, no al informe | Las regiones del norte encabezan (Atacama, 3,69) y las del centro-sur cierran (Maule, 2,43), pero la diferencia está confundida con la composición de carreras de cada región.                     |
| Ranking de instituciones | Al tablero, no al informe | Con umbral de tamaño es informativo, pero responde una pregunta operativa y no un objetivo declarado.                                                                                              |
| Matriz de dispersión     | Descartada                | Herramienta exploratoria: muestra mucho y no afirma nada.                                                                                                                                          |

## 4.7 Modelación desde primeros principios

Los modelos implementados en la Fase 3 —regresión lineal y logística por descenso de gradiente, sin bibliotecas de aprendizaje automático— se ejecutan sobre el conjunto analítico para cuantificar la asociación de cada factor. La regresión lineal se contrasta con su solución cerrada por ecuaciones normales, que es exacta, para verificar que la optimización converge al óptimo.

**Tabla 15.** Coeficientes de la regresión lineal y logística (variables estandarizadas)

| Variable                              | Gradiente | Solución cerrada | Diferencia | Logística |
|---------------------------------------|-----------|------------------|------------|-----------|
| dur_total_carr                        | -0,382    | -0,382           | 0,000      | 0,055     |
| edad_ingreso                          | -0,525    | -0,525           | 0,000      | 0,291     |
| genero=Mujer                          | -0,405    | -0,405           | 0,000      | 0,128     |
| tipo_inst_1=Institutos Profesionales  | -0,544    | -0,544           | 0,000      | 0,889     |
| tipo_inst_1=Universidades             | 0,916     | 0,916            | 0,000      | -0,040    |
| area_conocimiento=Agropecuaria        | 0,712     | 0,712            | 0,000      | -0,377    |
| area_conocimiento=Arte y Arquitectura | 0,002     | 0,002            | 0,000      | 0,109     |
| area_conocimiento=Ciencias Básicas    | 1,358     | 1,364            | 0,006      | -0,423    |
| area_conocimiento=Ciencias Sociales   | -0,522    | -0,522           | 0,000      | 0,159     |
| area_conocimiento=Derecho             | 2,862     | 2,862            | 0,000      | -0,475    |
| area_conocimiento=Educación           | -0,802    | -0,802           | 0,000      | 0,329     |
| area_conocimiento=Humanidades         | -0,543    | -0,554           | 0,012      | 0,149     |
| area_conocimiento=Salud               | -0,377    | -0,377           | 0,000      | 0,452     |
| area_conocimiento=Tecnología          | 0,906     | 0,906            | 0,000      | -0,304    |
| modalidad=Presencial                  | -0,145    | -0,145           | 0,000      | -0,250    |
| modalidad=Semipresencial              | 0,017     | 0,017            | 0,001      | 0,103     |

**Tabla 16.** Efecto del umbral de decisión en la regresión logística

| Umbral | Exactitud | Precisión | Sensibilidad | F1    |
|--------|-----------|-----------|--------------|-------|
| 0,50   | 0,812     | 0,450     | 0,040        | 0,074 |
| 0,40   | 0,803     | 0,404     | 0,119        | 0,184 |
| 0,30   | 0,773     | 0,374     | 0,320        | 0,345 |
| 0,19   | 0,676     | 0,309     | 0,596        | 0,407 |

El descenso de gradiente implementado a mano converge a la misma solución que las ecuaciones normales, lo que valida la implementación, y los coeficientes son coherentes con el análisis descriptivo. Pero el poder explicativo es bajo: un  $R^2$  de 0,085 en el conjunto de prueba significa que las variables institucionales y demográficas disponibles explican una fracción pequeña de la variación individual. En clasificación el resultado es más elocuente todavía: con un 19 % de titulación oportuna, predecir siempre «no oportuna» acierta el 81,3 %, y el modelo con umbral 0,5 alcanza 81,2 %. No supera a la regla trivial.

Bajar el umbral a la prevalencia (0,19) eleva la sensibilidad al 59,6 % a costa de la precisión, lo que convierte la elección del umbral en una decisión de política —a cuántos estudiantes acompañar— y no en un problema estadístico.

## 4.8 El relato de los hallazgos

Un gráfico aislado informa; una secuencia de gráficos argumenta. Las tres figuras de este apartado están encadenadas de forma deliberada, y el color cumple la misma función en las tres, señala aquello sobre lo que se dirige la mirada, mientras el gris es siempre el contexto.

**Tabla 17.** Función de cada figura en el argumento

| Movimiento | Figura   | Qué aporta                                                                    |
|------------|----------|-------------------------------------------------------------------------------|
| Contexto   | Figura 1 | Establece la magnitud: el rezago es la norma y no la excepción                |
| Contraste  | Figura 2 | Localiza dónde se concentra: el rezago no se reparte de forma pareja          |
| Resolución | Figura 3 | Confirma el patrón en otra dimensión y declara hasta dónde alcanza la lectura |

Cuatro de cada cinco titulados de pregrado en Chile egresan fuera del plazo que su propio plan de estudios declara, con un exceso medio de 2,76 semestres que suma 3.551.990 semestres-estudiante en el período. Ese rezago no se reparte de forma pareja: Derecho triplica a Educación, las universidades superan a institutos y centros de formación técnica, y las mujeres se titulan casi un semestre antes de manera consistente en las diez áreas, diferencia que resiste la estratificación. La dimensión temporal confirma el patrón y revela sus límites, la caída de titulaciones de 2020 y el máximo de 2021 son el mismo fenómeno, y el descenso posterior no puede leerse como mejora porque ninguna cohorte del período está completa.

Nada de esto explica el caso individual. Los modelos alcanzan un  $R^2$  de 0,085 y su clasificación no supera a la regla trivial. El rezago responde a trayectorias personales que los registros administrativos no contienen. Esa conclusión negativa delimita el alcance legítimo de este tipo de fuente, y es un resultado del trabajo tanto como las cifras anteriores.

## 5. Discusión

### 5.1 Contraste con las hipótesis iniciales

La Fase 1 planteó tres hipótesis de trabajo. El análisis final permite evaluarlas con evidencia.

**Tabla 18.** Hipótesis iniciales frente a los resultados obtenidos

| Hipótesis (Fase 1)                                                  | Evidencia (Fase 4)                                                                       | Veredicto  |
|---------------------------------------------------------------------|------------------------------------------------------------------------------------------|------------|
| La duración real supera sistemáticamente a la teórica               | Sobreduración media de 2,76 semestres; solo el 19,0 % se titula en plazo                 | Confirmada |
| El rezago difiere por área de conocimiento y tipo de institución    | Derecho triplica a Educación; las universidades superan a IP y CFT en más de un semestre | Confirmada |
| Las variables disponibles permitirían predecir el rezago individual | R <sup>2</sup> de 0,085; la clasificación no supera la línea base                        | Refutada   |

La tercera hipótesis es la más valiosa precisamente porque no se cumplió. Muestra que el rezago es un fenómeno individual que los registros administrativos no capturan, y acota qué tipo de conclusiones puede sostener esta fuente. Un proyecto que solo confirmara lo que esperaba habría aprendido menos.

### 5.2 Limitaciones y riesgos

1. Sesgo de truncamiento. Ninguna cohorte está completa y las recientes están sesgadas hacia los estudiantes rápidos. Riesgo asociado: leer el descenso de la serie desde 2024 como una mejora del sistema. Mitigación adoptada: restringir las comparaciones longitudinales a cohortes con horizonte equivalente y documentar el sesgo explícitamente.
2. Sesgo de supervivencia. La base contiene únicamente a quienes se titularon. La deserción, probablemente la consecuencia más grave del rezago, es invisible. Riesgo: subestimar el problema, porque quien abandonó tras años de rezago no aparece.
3. Duración teórica declarada. La reporta cada institución y no está auditada. Un plan subdeclarado infla artificialmente la sobreduración medida de esa carrera.
4. Reconstrucción de la duración real. Supone continuidad de la trayectoria: no distingue entre un estudiante que cursó sin interrupciones y otro que congeló dos años. El indicador mide tiempo transcurrido, no tiempo cursado.

5. Variables ausentes. No hay información sobre situación laboral, financiamiento, salud ni carga familiar, que es justamente donde el modelo sugiere que reside la explicación. El bajo  $R^2$  es evidencia de esa ausencia, no de un error de especificación.
6. Unidad de análisis. La fuente registra procesos de titulación, no personas: un estudiante con dos títulos aparece dos veces. Para las preguntas de este proyecto es la unidad correcta, pero impide leer los resultados como proporciones de personas.

### 5.3 Relación entre las fases y decisiones determinantes

Cada fase habilitó la siguiente, y algunas decisiones tempranas resultaron más determinantes de lo previsto.

- **F1 → F2.** Fijar las versiones de las dependencias y separar el código en módulos desde el inicio permitió que el pipeline creciera de 5 a 16 módulos sin reescrituras. Es la decisión de menor costo y mayor rendimiento del proyecto.
- **F2 → F3.** Disponer de un dataset validado hizo posible verificar cada algoritmo propio contra una referencia independiente sobre datos reales, y no sobre casos sintéticos. La corrección quedó establecida antes de medir la eficiencia.
- **F3 → F4.** El motor de reglas de la Fase 2 se reutilizó sin modificación sobre los artefactos de la Fase 3, y la fachada permitió que el notebook final coordine nueve módulos con cinco llamadas. La modularidad no fue un ejercicio académico: redujo trabajo real.
- **La decisión más costosa de revertir.** Marcar los atípicos en lugar de eliminarlos, en la Fase 2. Conservarlos permitió medir su efecto en la Fase 4 en vez de tener que rehacer la limpieza. La regla general que dejó el proyecto: cuando una decisión de limpieza es discutible, márcala y documéntala en vez de aplicarla de forma irreversible.

## 6. Conclusiones

### 6.1 Hallazgos sustantivos

1. Cuatro de cada cinco titulados de pregrado en Chile egresan fuera del plazo que su plan de estudios declara. El exceso medio es de 2,76 semestres, un 43 % sobre lo previsto, y suma 3.551.990 semestres-estudiante en el período analizado.
2. El rezago es estructural y no aleatorio. Derecho triplica a Educación, las universidades superan a institutos y centros de formación técnica, y las mujeres se titulan casi un semestre antes que los hombres de manera consistente en las diez áreas de conocimiento.
3. La pandemia desplazó titulaciones en lugar de empeorarlas. La caída de 2020 y el máximo de 2021 son el mismo fenómeno observado en dos momentos: un efecto de calendario administrativo, no de deterioro del desempeño académico.
4. Los registros administrativos no explican el rezago individual. Con un  $R^2$  de 0,085 y una clasificación que no supera la línea base, el fenómeno responde a factores que la fuente no contiene. Esta conclusión negativa delimita el alcance legítimo de este tipo de análisis.

### 6.2 Aprendizajes técnicos

- **Verificar antes de optimizar.** Cada algoritmo propio se contrastó con una referencia independiente antes de medir su tiempo. Medir un algoritmo incorrecto no aporta información.
- **La cota teórica no basta.** El exponente empírico de quickselect (1,22 frente al 1,00 teórico) mostró que el análisis asintótico describe el crecimiento, pero no la constante ni el costo de asignar memoria. La medición y la teoría son complementarias, no sustitutas.
- **Los invariantes pertenecen al objeto.** Trasladar las reglas del dominio a Titulado y Cohorte eliminó una clase entera de errores: un objeto no puede existir en estado incoherente.
- **Un fallo silencioso es peor que uno ruidoso.** Las tres mejoras de reproducibilidad aplicadas tras la Fase 2 comparten ese criterio, y las tres nacieron de un problema real detectado al reproducir el proyecto en un segundo equipo.

- **Los datos imponen sus propios límites.** El sesgo de truncamiento no se descubrió leyendo la documentación de la fuente, sino al cruzar cohorte de ingreso con año de titulación. Explorar los datos desde un ángulo nuevo reveló una limitación que ninguna fase anterior había detectado.

### 6.3 Mejoras propuestas, basadas en la evidencia del proyecto

**Tabla 19.** Mejoras priorizadas y evidencia que las motiva

| Mejora                                                         | Evidencia que la motiva                                                              | Impacto esperado                                               |
|----------------------------------------------------------------|--------------------------------------------------------------------------------------|----------------------------------------------------------------|
| Partición in situ (Hoare) en quickselect                       | Pico de 4.422 KB, el mayor del núcleo; exponente empírico 1,22 frente a 1,00 teórico | Menor consumo de memoria y escalamiento acorde a la cota       |
| Versiones iterativas de merge sort y búsqueda binaria          | Ambas dependen del límite de recursión de Python                                     | Procesar el dataset completo sin reservas sobre la profundidad |
| Incorporar la base de matrícula además de la de titulados      | El sesgo de supervivencia oculta la deserción                                        | Estimar el rezago sin condicionar a haber egresado             |
| Modelo de supervivencia en lugar de regresión lineal           | El truncamiento por cohorte invalida la comparación longitudinal directa             | Estimaciones válidas con datos censurados por la derecha       |
| Perfilado por líneas además de timeit                          | Se sabe cuánto tarda cada función, pero no en qué línea se consume el tiempo         | Optimizar con evidencia en lugar de intuición                  |
| Ampliar el modelo con interacciones y variables de trayectoria | $R^2$ de 0,085 con las variables disponibles                                         | Mayor poder explicativo, si se accede a nuevas fuentes         |

### 6.4 Comunicación de resultados

Los resultados se comunican en cuatro soportes complementarios, todos versionados en el repositorio:

- Los notebooks, para quien necesite auditar el procedimiento completo, celda por celda.
- Este informe, para la lectura estructurada del análisis y sus fundamentos.
- Un tablero interactivo, alimentado por scripts/exportar\_powerbi.py, que permite a un tercero explorar los cortes por institución, área, territorio y cohorte sin ejecutar código. Incluye el score de riesgo del modelo logístico y un control de umbral que hace tangible el compromiso entre cobertura y capacidad de atención.

- Una presentación audiovisual de entre cinco y ocho minutos que sintetiza problema, metodología, resultados y conclusiones.

## 7. Trazabilidad de mejoras

Las mejoras aplicadas a lo largo del proyecto están registradas en CHANGELOG.md, en la raíz del repositorio, vinculadas al commit que las implementa. Cada fila puede verificarse con `git show` sobre el hash indicado.

**Tabla 20.** Mejoras aplicadas, commit de implementación e impacto técnico

| Problema detectado                                                                | Mejora aplicada                                                                  | Commit  | Impacto                                                        |
|-----------------------------------------------------------------------------------|----------------------------------------------------------------------------------|---------|----------------------------------------------------------------|
| La normalización de texto recorría fila por fila 1,7 millones de cadenas          | Se normaliza el catálogo de valores únicos y se mapea de vuelta                  | 5e07669 | Rendimiento: de 1,7 M de operaciones a unos 8 mil              |
| Los tipos anulables de pandas rompían matplotlib y propagaban NA en comparaciones | Conversión explícita a float64 antes de graficar; NA tratados al marcar atípicos | f698c37 | Corrección: 19 filas dejaban de marcarse en silencio           |
| La celda de pruebas usaba el intérprete del kernel y fallaba sin mostrar la causa | Apunta al intérprete del entorno virtual e imprime stderr si falla               | b8770f5 | Reproducibilidad: fallo diagnosticable en vez de silencioso    |
| Los notebooks dependían del Parquet completo, no versionado                       | Degradación automática a la muestra de 5.000 registros con aviso                 | 40be4d9 | Reproducibilidad: el proyecto corre sin datos externos         |
| Los invariantes del dominio no estaban garantizados en ninguna parte              | Modelo de dominio con validación en setters y derivadas de solo lectura          | a1342a5 | Modularidad: imposible construir un objeto incoherente         |
| La agregación recorría la secuencia una vez por grupo, $O(n \cdot k)$             | Agregación en una sola pasada $O(n)$ con dos acumuladores                        | 8d87723 | Rendimiento: 1,9× en tiempo y 860× en memoria                  |
| Los conteos por umbral recorrían la lista completa por categoría                  | Dos búsquedas binarias recursivas sobre una copia ordenada                       | 8d87723 | Rendimiento: 6.516× más rápido que el recorrido lineal         |
| El descenso de gradiente devolvía pesos infinitos con tasas altas                 | Detección explícita de divergencia con excepción accionable                      | 40be4d9 | Robustez: error claro en vez de resultado inválido             |
| El informe de la Fase 3 no seguía la estructura mínima exigida                    | Reorganización completa según la pauta de la asignatura                          | b5523ad | Documentación: correspondencia con los criterios de evaluación |
| Una cifra del informe comparaba contra la implementación equivocada               | Verificación cruzada contra reports/tables y corrección del dato                 | 21cfbb9 | Confiabilidad: toda cifra rastreable a su archivo de origen    |

El criterio común a las diez mejoras es el mismo que atraviesa el proyecto: hacer explícito lo que fallaba en silencio, y dejar registro verificable de por qué se cambió.

## 8. Repositorio y notebooks

### 8.1 Estructura del repositorio

#### Organización del repositorio por fases

|                     |                                                                 |                                   |
|---------------------|-----------------------------------------------------------------|-----------------------------------|
| proyecto-titulados/ |                                                                 |                                   |
| -- F1/              | F1_Definición.ipynb                                             | Definición del problema y entorno |
| -- F2/              | F2_1 · F2_2 · F2_3 .ipynb                                       | Obtención, limpieza y validación  |
| -- F3/              | F3_Nucleo_Algoritmico.ipynb                                     | Algoritmos, complejidad y POO     |
| -- F4/              | F4_Reporte_Analitico.ipynb                                      | Reporte integrador (esta fase)    |
| -- src/             | 16 módulos: pipeline de F2 y subpaquete núcleo/ de F3           |                                   |
| -- tests/           | 73 pruebas (22 del pipeline + 51 del núcleo)                    |                                   |
| -- reports/         | figures/ y tables/ con todas las salidas de los notebooks       |                                   |
| -- informe/         | Los cuatro informes y sus evidencias por fase                   |                                   |
| -- powerbi/         | Guía del tablero de comunicación de resultados                  |                                   |
| -- scripts/         | exportar_powerbi.py                                             |                                   |
| -- docs/            | Esquema oficial del SIES y mapa conceptual técnico              |                                   |
| -- data/            | processed/ con la muestra versionada; raw/ e interim/ ignorados |                                   |
| -- CHANGELOG.md     | Trazabilidad de mejoras vinculada a commits                     |                                   |
| -- requirements.txt | Dependencias con versión fijada                                 |                                   |
| -- README.md        | Instalación, ejecución por fase y decisiones técnicas           |                                   |

El README documenta la instalación del entorno, la ejecución de cada notebook con su tiempo estimado, las funciones del núcleo con su complejidad declarada y los criterios de optimización aplicados. El CHANGELOG registra la evolución del proyecto vinculada a commits verificables.

### 8.2 Notebooks del proyecto

**Tabla 21.** Notebooks, contenido y correspondencia con este informe

| Notebook                     | Contenido                                        | Apartado del informe |
|------------------------------|--------------------------------------------------|----------------------|
| F1_Definición                | Problema, entorno reproducible, esquema de datos | 1, 2, 3.4            |
| F2_1_Obtencion_Exploracion   | Consolidación de los 6 CSV y exploración inicial | 3.5                  |
| F2_2_Limpieza_Transformacion | Centinelas, duplicados y variables derivadas     | 3.5                  |
| F2_3_Validacion_Analisis     | Reglas de validación y primeros resultados       | 3.8                  |
| F3_Nucleo_Algoritmico        | Algoritmos, complejidad, POO y modelación        | 3.6, 3.7             |
| F4_Reporte_Analitico         | Integración F1-F4, figuras finales y discusión   | 4, 5, 6              |

Los seis notebooks se ejecutan de corrido sin errores. El de la Fase 4 no repite el trabajo de las anteriores: importa el pipeline de la Fase 2 y el núcleo de la Fase 3 a través de la fachada, de modo que ninguna lógica se redefine en celdas. Las tablas que produce se exportan a reports/tables/f4\_\*.csv y las figuras a reports/figures/f4\_\*.png; todas las cifras de este informe provienen de esos archivos.

## 9. Referencias

*Referencias en formato APA 7.ª edición, citadas en el cuerpo del informe y en los notebooks.*

### Bibliografía docente

Contreras Bravo, L. E., & Padilla Beltrán, J. E. (2024). Ciencia de datos con Python: transformación y selección de variables. Ediciones de la U.

Grus, J. (2019). Data science from scratch: First principles with Python (2.ª ed.). O'Reilly Media.

Wickham, H., & Grolemund, G. (2017). R para la ciencia de datos: importar, ordenar, transformar, visualizar y modelar datos. O'Reilly Media. <https://es.r4ds.hadley.nz/>

Tesis “Predicción de duración de estudios Pregrado SIES 2007 a 2020” (2024), Carlos Labarca Jara / Sebastian Antunez Noguera, Universidad Andres Bello, Magister en Gestión de Tecnologías y Telecomunicaciones.

### Fuente de datos

Servicio de Información de Educación Superior. (2025). Titulados de Educación Superior 2020-2025 [conjunto de datos]. Ministerio de Educación de Chile. <https://www.mifuturo.cl/bases-de-datos-de-titulados/>

### Documentación técnica oficial

NumPy Developers. (2025). NumPy documentation (versión 2.5). <https://numpy.org/doc/stable/>

pandas Development Team. (2025). pandas documentation (versión 3.0). <https://pandas.pydata.org/docs/>

Python Software Foundation. (2025a). timeit — Measure execution time of small code snippets. <https://docs.python.org/3/library/timeit.html>

Python Software Foundation. (2025b). tracemalloc — Trace memory allocations.

<https://docs.python.org/3/library/tracemalloc.html>

Python Software Foundation. (2025c). abc — Abstract base classes.

<https://docs.python.org/3/library/abc.html>

## **Bibliografía complementaria**

Cormen, T. H., Leiserson, C. E., Rivest, R. L., & Stein, C. (2022). Introduction to algorithms (4.<sup>a</sup> ed.). MIT Press.

Gamma, E., Helm, R., Johnson, R., & Vlissides, J. (1994). Design patterns: Elements of reusable object-oriented software. Addison-Wesley.

Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., Wieser, E., Taylor, J., Berg, S., Smith, N. J., Kern, R., Picus, M., Hoyer, S., van Kerkwijk, M. H., Brett, M., Haldane, A., del Río, J. F., Wiebe, M., Peterson, P., ... Oliphant, T. E. (2020). Array programming with NumPy. Nature, 585(7825), 357-362. <https://doi.org/10.1038/s41586-020-2649-2>

McKinney, W. (2022). Python for data analysis: Data wrangling with pandas, NumPy, and Jupyter (3.<sup>a</sup> ed.). O'Reilly Media.

Ramalho, L. (2022). Fluent Python: Clear, concise, and effective programming (2.<sup>a</sup> ed.). O'Reilly Media.

## Anexos

### Anexo A. Salida completa de las pruebas automatizadas

```

===== test session starts =====
platform win32 -- Python 3.14.7, pytest-9.1.1, pluggy-1.6.0 -- D:\Magister Ciencia de Datos\P...
cachedir: .pytest_cache
rootdir: D:\Magister Ciencia de Datos\Programacion para la Ciencia\Sumativas\proyecto-titulados
plugins: anyio-4.15.1
collecting ... collected 73 items
tests/test_nucleo.py::TestAgrupacion::test_media_por_grupo_coincide_con_pandas PASSED [ 1%]
tests/test_nucleo.py::TestAgrupacion::test_un_solo_grupo PASSED [ 2%]
tests/test_nucleo.py::TestAgrupacion::test_largos_distintos_lanzan_error PASSED [ 4%]
tests/test_nucleo.py::TestOrdenamiento::test_merge_sort_coincide_con_sorted PASSED [ 5%]
tests/test_nucleo.py::TestOrdenamiento::test_no_muta_la_entrada PASSED [ 6%]
tests/test_nucleo.py::TestOrdenamiento::test_vacia_y_un_elemento PASSED [ 8%]
tests/test_nucleo.py::TestOrdenamiento::test_es_estable PASSED [ 9%]
tests/test_nucleo.py::TestSeleccion::test_mediana_coincide_con_statistics PASSED [ 10%]
tests/test_nucleo.py::TestSeleccion::test_quickselect_recupera_cada_posicion PASSED [ 12%]
tests/test_nucleo.py::TestSeleccion::test_mediana_par_e_impar PASSED [ 13%]
tests/test_nucleo.py::TestSeleccion::test_k_fuera_de_rango_y_vacia PASSED [ 15%]
tests/test_nucleo.py::TestBusqueda::test_binaria_encuentra_y_no_encuentra PASSED [ 16%]
tests/test_nucleo.py::TestBusqueda::test_binaria_en_vacia PASSED [ 17%]
tests/test_nucleo.py::TestBusqueda::test_conteos_por_umbral_coinciden_con_recuento_directo PA...
tests/test_nucleo.py::TestBusqueda::test_cotas_en_bordes PASSED [ 20%]
tests/test_nucleo.py::TestBenchmark::test_medicion_basica PASSED [ 21%]
tests/test_nucleo.py::TestBenchmark::test_exponente_de_funcion_lineal_cercano_a_uno PASSED [ ...
tests/test_nucleo.py::TestBenchmark::test_exponente_cuadratico PASSED [ 24%]
tests/test_nucleo.py::TestBenchmark::test_estimar_orden_exige_dos_tamano PASSED [ 26%]
tests/test_nucleo.py::TestBenchmark::test_comparar_ordena_por_tiempo PASSED [ 27%]
tests/test_nucleo.py::TestTitulado::test_propiedades_derivadas PASSED [ 28%]
tests/test_nucleo.py::TestTitulado::test_encapsulamiento_identidad_solo_lectura PASSED [ 30%]
tests/test_nucleo.py::TestTitulado::test_setters_validan PASSED [ 31%]
tests/test_nucleo.py::TestTitulado::test_orden_natural_e_igualdad PASSED [ 32%]
tests/test_nucleo.py::TestTitulado::test_desde_fila_con_dict_y_series PASSED [ 34%]
tests/test_nucleo.py::TestCohorte::test_protocolo_de_secuencia PASSED [ 35%]
tests/test_nucleo.py::TestCohorte::test_filtrar_y_agrupar_no_mutan PASSED [ 36%]
tests/test_nucleo.py::TestCohorte::test_strategy_con_metricas PASSED [ 38%]
tests/test_nucleo.py::TestCohorte::test_ordenados_con_merge_sort PASSED [ 39%]
tests/test_nucleo.py::TestCohorte::test_agregar_rechaza_tipos_ajenos PASSED [ 41%]
tests/test_nucleo.py::TestCohorte::test_metrica_en_cohorte_vacia_lanza_error PASSED [ 42%]
tests/test_nucleo.py::TestCohorte::test_desde_dataframe_exige_columnas PASSED [ 43%]
tests/test_nucleo.py::TestCohorte::test_percentil_valida_rango PASSED [ 45%]
tests/test_nucleo.py::TestJerarquia::test_totales_rekursivos_y_estructura PASSED [ 46%]
tests/test_nucleo.py::TestJerarquia::test_cache_se_invalida_al_insertar PASSED [ 47%]
tests/test_nucleo.py::TestJerarquia::test_metrica_composite_y_descenso PASSED [ 49%]
tests/test_nucleo.py::TestJerarquia::test_buscar_y_dataframe PASSED [ 50%]
tests/test_nucleo.py::TestJerarquia::test_nodo_vacio PASSED [ 52%]
tests/test_nucleo.py::TestPreparacion::test_escalador_estandar PASSED [ 53%]
tests/test_nucleo.py::TestPreparacion::test_estandar_invertir PASSED [ 54%]
tests/test_nucleo.py::TestPreparacion::test_minmax_en_cero_uno PASSED [ 56%]
tests/test_nucleo.py::TestPreparacion::test_transformar_sin_ajustar_y_dimensiones PASSED [ 57%]
tests/test_nucleo.py::TestPreparacion::test_onehot_omite_primera_y_categoria_desconocida PASS...
tests/test_nucleo.py::TestPreparacion::test_particion_reproducibile_y_disjunta PASSED [ 60%]

```

```

tests/test_nucleo.py::TestPreparacion::test_preparador_compone_y_exige_ajuste PASSED [ 61%]
tests/test_nucleo.py::TestModelos::test_descenso_converge_a_solucion_cerrada PASSED [ 63%]
tests/test_nucleo.py::TestModelos::test_perdida_decrece PASSED [ 64%]
tests/test_nucleo.py::TestModelos::test_logistica_separa_datos_separables PASSED [ 65%]
tests/test_nucleo.py::TestModelos::test_pesos_devueltos_son_copia PASSED [ 67%]
tests/test_nucleo.py::TestModelos::test_errores_controlados PASSED [ 68%]
tests/test_nucleo.py::TestModelos::test_metricas_clasificacion_extremos PASSED [ 69%]
tests/test_pipeline.py::test_duracion_real_caso_normal PASSED [ 71%]
tests/test_pipeline.py::test_sobreduracion_y_categoria PASSED [ 72%]
tests/test_pipeline.py::test_edad_descuenta_mes_no_cumplido PASSED [ 73%]
tests/test_pipeline.py::test_edad_cuando_aun_no_cumple_anios PASSED [ 75%]
tests/test_pipeline.py::test_semestre_de_titulacion_segun_mes PASSED [ 76%]
tests/test_pipeline.py::test_duracion_minima_es_uno PASSED [ 78%]
tests/test_pipeline.py::test_clasificacion_en_los_bordes PASSED [ 79%]
tests/test_pipeline.py::test_sentinelas_se_convierten_en_na PASSED [ 80%]
tests/test_pipeline.py::test_normalizacion_de_texto_respetar_nombres_propios PASSED [ 82%]
tests/test_pipeline.py::test_duplicados_sin_mrur_no_se_colapsan PASSED [ 83%]
tests/test_pipeline.py::test_duplicado_exacto_se_elimina PASSED [ 84%]
tests/test_pipeline.py::test_duracion_teorica_cero_no_divide_por_cero PASSED [ 86%]
tests/test_pipeline.py::test_registro_sin_fecha_nacimiento_se_marca_atipico PASSED [ 87%]
tests/test_pipeline.py::test_archivos_faltantes_lanza_excepcion PASSED [ 89%]
tests/test_pipeline.py::test_cargar_consolidado_inexistente PASSED [ 90%]
tests/test_pipeline.py::test_validador_detecta_dataset_corrupto PASSED [ 91%]
tests/test_pipeline.py::test_validador_aprueba_dataset_correcto PASSED [ 93%]
tests/test_pipeline.py::test_estado_antes_de_ejecutar_lanza_error PASSED [ 94%]
tests/test_pipeline.py::test_regla_con_excepcion_se_reporta_como_falla PASSED [ 95%]
tests/test_pipeline.py::test_tabla_agregada_respetar_minimo_de_casos PASSED [ 97%]
tests/test_pipeline.py::test_formato_numerico_chileno PASSED [ 98%]
tests/test_pipeline.py::test_configuracion_expone_versiones PASSED [100%]
===== 73 passed in 1.65s =====

```

## Anexo B. Historial completo de commits

| Hash    | Fecha      | Mensaje                                                                     |
|---------|------------|-----------------------------------------------------------------------------|
| 21cfbb9 | 2026-09-27 | feat(f4): notebook del reporte analítico integrador con cuatro figuras      |
| 7538f5c | 2026-09-24 | chore(f3): re-ejecuta los notebooks en el entorno local y actualiza salidas |
| b5523ad | 2026-09-24 | docs(f3): versión final del informe                                         |
| b62d36a | 2026-09-21 | docs(f3): informe y evidencias alineados con el historial definitivo        |
| 9062995 | 2026-09-21 | merge: integra la rama fase-3/nucleo-algoritmico en main                    |
| 58cb930 | 2026-09-19 | docs(f3): actualiza el informe y las evidencias con el historial definitivo |
| b769379 | 2026-09-19 | docs(f3): agrega el PDF del informe con la fecha de entrega                 |
| d10b470 | 2026-09-19 | docs(f3): Primer Informe F3                                                 |
| 6d348f8 | 2026-09-19 | docs(f3): informe técnico de la Fase 3 y evidencias de ejecución            |
| b8770f5 | 2026-09-19 | docs(f3): notebook del núcleo algorítmico ejecutado de corrido              |
| d6df25e | 2026-09-19 | test(nucleo): 51 pruebas de casos normales, límite y excepciones            |
| 40be4d9 | 2026-09-19 | feat(nucleo): preparación, modelos por descenso de gradiente y fachada      |
| a1342a5 | 2026-09-19 | feat(nucleo): modelo de dominio orientado a objetos                         |

| Hash    | Fecha      | Mensaje                                                                     |
|---------|------------|-----------------------------------------------------------------------------|
| 8d87723 | 2026-09-19 | feat(nucleo): algoritmos estructurados y recursivos con analisis de comp... |
| 76867c7 | 2026-09-15 | chore: prepara la rama de la Fase 3 y sanea el repositorio                  |
| 807ad02 | 2026-09-09 | Reejecucion de notebook en el equipo de trabajo con documento pdf           |
| 9d8c578 | 2026-09-09 | Reejecucion de notebook en el equipo de trabajo con Jupyter LAB             |
| 75b8d4b | 2026-09-09 | Reejecucion de notebook en el equipo de trabajo                             |
| 5d76ade | 2026-09-08 | docs: actualiza el informe y el notebook F1 tras corregir la autoria        |
| 004de50 | 2026-09-08 | docs(informe): agrega el informe tecnico de las Fases 1 y 2                 |
| b70eaad | 2026-09-08 | style(viz): corrige la acentuacion de las etiquetas de los graficos         |
| 4418158 | 2026-09-08 | style(viz): rotula las figuras con formato numerico chileno                 |
| b1021bc | 2026-09-08 | merge: integra la rama fase-2/pipeline-datos en main                        |
| fc75c8f | 2026-09-08 | docs(f2): ejecuta los notebooks y versiona figuras, tablas y muestra        |
| 5e07669 | 2026-09-08 | perf(limpieza): normaliza el catalogo de categorias en vez de fila por fila |
| f698c37 | 2026-09-08 | fix(viz,transformacion): compatibilidad con los tipos anulables de pandas   |
| 8334b7f | 2026-09-08 | docs(f2): notebooks de obtencion, limpieza, transformacion y validacion     |
| d070aef | 2026-09-08 | docs(f1): notebook de definicion del proyecto y entorno reproducible        |
| 997c0d1 | 2026-09-08 | feat(viz,pipeline): estilo unificado de figuras y orquestador ejecutable    |
| 6d2bb5f | 2026-09-08 | test: cubre casos normales, limite y excepciones del pipeline               |
| 2b8a0f2 | 2026-09-08 | feat(validacion): motor de reglas orientado a objetos                       |
| a90d244 | 2026-09-08 | feat(transformacion): reconstruye la duracion real y la sobreduracion       |
| bf45180 | 2026-09-08 | feat(limpieza): convierte codigos centinela del SIES en nulos explicitos    |
| c8bb51e | 2026-09-08 | feat(ingesta): consolida los seis anios con lectura por bloques             |
| 02cd383 | 2026-09-08 | feat(config): centraliza rutas, esquema de datos y parametros               |
| 8d219de | 2026-09-08 | chore: inicializa repositorio con entorno reproducible                      |

## Anexo C. Contribuciones y ramas

git shortlog -sn --all

|    |                                                               |
|----|---------------------------------------------------------------|
| 45 | Sebastian Antunez Noguera <s.antuneznoguera@uandresbello.edu> |
|    |                                                               |
|    |                                                               |

*El proyecto es de autoría individual. Las dos identidades que registró el historial quedan unificadas por el archivo .mailmap de la raíz del repositorio: la salida anterior, obtenida con ese archivo activo, informa un solo autor.*